IAE Nantes
Économie & Management
Pôle Sociétés

Analyse et prévision

d'une série saisonnière mensuelle

Trafic aérien commercial mensuel en France

Réalisé par :

Amélie PIRES

Encadré par :

Olivier DARNÉ

M1 ECAP - *Techniques de Prévision et Conjoncture*

Année universitaire 2025 - 2026

Sommaire

INTRODUCTION **3**

1. Analyse exploratoire de la série **4**
1.1 Présentation de la série 4
1.2 Détection et correction des points atypiques 5
1.3 Statistiques descriptives sur la série corrigée 7
1.4 Mise en évidence de la saisonnalité 8
1.5 Désaisonnalisation et décomposition X13-SARIMA-SEATS 10

2. Prévision de la série **12**
2.1 Méthodes de référence : naïve saisonnière, X13, STL, STS 12
2.2 Méthodes de lissage exponentiel : Holt-Winters, ETS, TBATS, ADAM 13
2.3 Modèles SARIMA : automatique, manuel et SSARIMA 14

3. Comparaison des modèles estimés **15**
3.1 Paramètres estimés et critères d'information 15
3.2 Comparaison graphique des prévisions 16

4. Évaluation out-of-sample des prévisions **18**
4.1 MSE et R^2 OOS 18
4.2 Erreurs cumulées de prévision : CSPE 19
4.3 Sélection du meilleur modèle 21

5. Test de Diebold-Mariano **21**
5.1 Principe du test 21
5.2 Résultats 22
5.3 Conclusion statistique 23

CONCLUSION **24**

ANNEXES **26**

INTRODUCTION

Dans ce dossier, j'étudie l'évolution du trafic aérien commercial mensuel en France entre janvier 2007 et décembre 2024. La série mesure le nombre total de passagers commerciaux, obtenu à partir des flux de départs et d'arrivées enregistrés chaque mois dans les aéroports français. Les données proviennent de la base "Trafic aérien commercial mensuel français", disponible sur le site data.gouv.fr. Il s'agit donc d'une série temporelle mensuelle composée de 216 observations, avec une fréquence égale à 12.

Cette série est intéressante pour un travail de prévision conjoncturelle. Elle est marquée par une saisonnalité annuelle forte, avec des niveaux de trafic généralement plus élevés pendant les mois d'été et plus faibles durant certaines périodes hivernales. Elle a également été fortement perturbée par la crise sanitaire liée au COVID-19, qui a entraîné une chute brutale du trafic aérien à partir de 2020. La série permet donc d'étudier à la fois une dynamique de long terme, une saisonnalité régulière et des chocs exceptionnels.

L'objectif du dossier est d'abord d'analyser les principales caractéristiques de la série. Pour cela, je présente son évolution générale, je détecte les points atypiques, puis je travaille sur une série corrigée afin d'étudier sa distribution, sa saisonnalité et sa décomposition par la méthode X13-SARIMA-SEATS.

Dans un second temps, je compare plusieurs méthodes de prévision, avec des méthodes de référence, des modèles de lissage exponentiel et des modèles SARIMA. Ces modèles sont évalués à partir de critères d'information, de graphiques de prévision, d'indicateurs out-of-sample comme le MSE, le R^2 OOS et le CSPE, puis du test de Diebold-Mariano.

L'enjeu est alors d'identifier le modèle le plus adapté pour prévoir le trafic aérien commercial mensuel en France, tout en tenant compte des spécificités de la série (sa tendance, sa saisonnalité et sa sensibilité aux chocs exceptionnels).

1. Analyse exploratoire de la série

1.1 Présentation de la série

La série étudiée porte sur le trafic aérien commercial mensuel en France. Elle mesure le nombre total de passagers commerciaux enregistrés chaque mois, en additionnant les passagers au départ et à l'arrivée. Les données initiales sont issues de fichiers mensuels relatifs aux flux de passagers, puis elles ont été regroupées afin d'obtenir une seule base mensuelle sur l'ensemble de la période. La variable finale retenue dans le code est donc `pax_total`, construite comme la somme des passagers au départ et des passagers à l'arrivée (Annexe A.1).

La période d'étude s'étend de janvier 2007 à décembre 2024. La série contient 216 observations mensuelles, avec une fréquence égale à 12. Cette fréquence permet d'observer les variations intra-annuelles du trafic aérien, notamment les hausses liées aux périodes de vacances et les niveaux plus faibles observés à d'autres moments de l'année.

Le graphique de la série brute met en évidence plusieurs caractéristiques importantes.

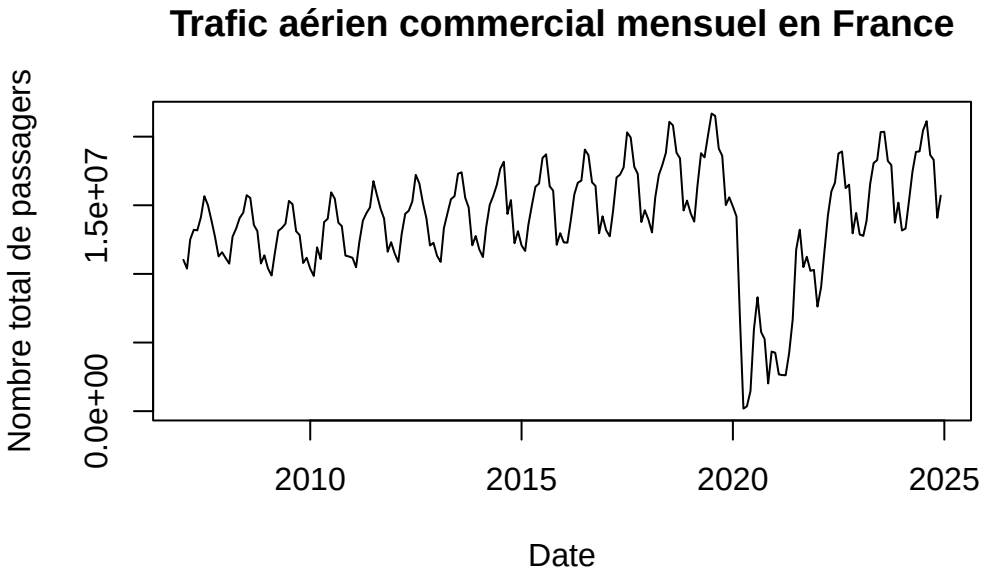


Figure 1: Évolution du trafic aérien commercial mensuel en France

On observe d'abord une tendance globalement croissante du trafic aérien entre 2007 et 2019. Cette progression traduit une augmentation régulière du nombre de passagers avant la crise sanitaire. À partir de 2020, la série présente une rupture très nette, avec une chute brutale du trafic liée au COVID-19 et aux restrictions de déplacement. Après ce choc, le trafic reprend progressivement, même si la dynamique reste marquée par les perturbations de 2020 et 2021.

Le graphique fait également apparaître une saisonnalité visuelle marquée. Les fluctuations semblent se répéter d'une année à l'autre, avec des pics et des creux revenant à des périodes

similaires. Cette première observation suggère que le trafic aérien dépend fortement du mois de l'année. Cette saisonnalité sera donc étudiée plus précisément à l'aide de l'autocorrélation, du périodogramme et de tests statistiques.

Les statistiques descriptives calculées sur la série brute donnent une première idée de son niveau et de sa dispersion. Le nombre moyen de passagers mensuels est d'environ 13,9 millions, avec un écart-type d'environ 4 millions. Le minimum est atteint en avril 2020, avec seulement 182 431 passagers, tandis que le maximum atteint environ 21,7 millions de passagers. Cet écart important s'explique à la fois par la saisonnalité du trafic aérien et par les chocs exceptionnels observés pendant la crise sanitaire.

Avant de poursuivre l'analyse, j'ai également vérifié la présence de valeurs manquantes. Le résultat indique qu'il n'y en a aucune dans la variable étudiée, ce qui permet de travailler directement sur la série temporelle sans appliquer de méthode d'imputation.

Cette première présentation met donc en évidence trois caractéristiques principales : une tendance à la hausse avant 2020, une saisonnalité mensuelle importante et un choc exceptionnel lié à la crise sanitaire. Ces éléments justifient la suite de l'analyse, qui consiste à détecter et corriger les points atypiques, puis à étudier plus précisément la saisonnalité et les prévisions.

1.2 Détection et correction des points atypiques

Après la présentation générale de la série, j'ai cherché à identifier les observations atypiques susceptibles de perturber l'analyse. Cette étape est nécessaire car la série brute présente des chocs très marqués, en particulier autour de la crise sanitaire. Ces valeurs extrêmes peuvent influencer les statistiques descriptives, la décomposition et les modèles de prévision.

Dans un premier temps, une détection simple par boxplot a été réalisée sur la série brute (Annexe B.1). Cette méthode met en évidence plusieurs valeurs atypiques basses, principalement concentrées entre 2020 et 2021. Ces observations correspondent à la période de restrictions sanitaires et de forte baisse du trafic aérien. Le minimum est notamment atteint en avril 2020, avec seulement 182 431 passagers, contre une moyenne mensuelle d'environ 13,9 millions sur la série brute comme dit plus tôt.

Le boxplot donne une première indication des valeurs atypiques. La correction retenue repose ensuite sur les résultats de `tso()` (Annexe B.2).

Les résultats obtenus mettent en évidence plusieurs points atypiques significatifs. Le tableau suivant résume les principales dates détectées :

Table 1: Tableau des points atypiques détectés par la méthode 'tso()'

Date	Type	Coefficient	t-stat
avril 2010	AO	-2 288 717	-7,231
septembre 2014	AO	-1 621 758	-5,148

mars 2020	LS	-9 824 133	-21,048
avril 2020	TC	-7 695 144	-16,995
juin 2020	AO	-3 453 934	-8,662
mars 2021	TC	-3 635 527	-8,122
juillet 2021	LS	4 057 187	10,044
novembre 2021	LS	2 933 197	7,102
décembre 2021	TC	-2 497 442	-5,784
janvier 2022	AO	-2 058 088	-5,428

Les outliers de type AO correspondent à des chocs ponctuels, les outliers de type LS à des changements de niveau plus durables, et les outliers de type TC à des effets temporaires dont l'impact diminue progressivement. Les résultats montrent que les années 2020 et 2021 concentrent les perturbations les plus importantes, ce qui est cohérent avec l'impact du COVID-19 sur le transport aérien.

Les premiers points atypiques détectés apparaissent en avril 2010 et en septembre 2014. Ils sont tous les deux de type AO et correspondent donc à des chocs ponctuels négatifs. Le point d'avril 2010 peut être associé à l'éruption du volcan islandais Eyjafjallajökull, dont le nuage de cendres avait fortement perturbé le trafic aérien européen. Le point de septembre 2014 peut lui être associé à la grève des pilotes d'Air France, qui avait affecté le trafic passagers et les mouvements d'avion, notamment à Paris-CDG et Orly. Leur effet est plus limité que celui observé pendant la crise sanitaire, mais ils montrent que la série a déjà connu, avant 2020, quelques baisses isolées du trafic aérien.

Le point atypique le plus marqué reste celui de mars 2020, identifié comme un changement de niveau avec une statistique de test très élevée en valeur absolue. Il correspond au début de la crise sanitaire et à la mise en place des restrictions de déplacement. Le mois d'avril 2020 est également détecté comme un choc temporaire important, ce qui correspond à l'arrêt presque complet d'une grande partie du trafic aérien. Le mois de juin 2020 apparaît aussi comme un choc ponctuel négatif, ce qui confirme que la baisse du trafic ne se limite pas à un seul mois.

Les points atypiques observés en 2021 et 2022 peuvent ensuite être interprétés comme les effets d'une reprise progressive mais encore instable. Les changements de niveau positifs détectés en juillet et novembre 2021 traduisent une remontée du trafic, alors que les chocs négatifs de décembre 2021 et janvier 2022 montrent que cette reprise reste perturbée.

À partir de ces résultats, j'ai construit une série corrigée des points atypiques (Annexe B.3). La comparaison graphique entre la série brute et la série corrigée montre que le choc de 2020-2021 est fortement atténué. La série corrigée permet ainsi d'étudier plus clairement la dynamique régulière du trafic aérien, notamment sa tendance, sa dispersion et sa saisonnalité.

Cette correction ne signifie pas que les chocs exceptionnels sont ignorés, ils sont d'abord identifiés et interprétés économiquement, puis corrigés afin d'éviter qu'ils ne biaisent les étapes

suivantes. La série corrigée sera donc utilisée pour les statistiques descriptives et pour l'étude de la saisonnalité.

1.3 Statistiques descriptives sur la série corrigée

Après avoir détecté les principaux points atypiques, j'ai travaillé sur la série corrigée afin d'obtenir des statistiques descriptives moins influencées par les chocs exceptionnels.

Table 2: Statistiques descriptives de la série corrigée

Statistique	Valeur
Nombre d'observations	216
Valeurs manquantes	0
Minimum	9 851 956
Maximum	23 958 993
Moyenne	15 505 752
Écart-type	3 119 066
Coefficient de variation	0,201
Skewness	0,444
Kurtosis	2,598
p-value Shapiro-Wilk	7,690000e-04

La correction modifie clairement la lecture de la série. Sur la série corrigée, le nombre moyen de passagers mensuels est d'environ 15,5 millions, contre environ 13,9 millions sur la série brute. Cet écart s'explique par la correction des valeurs très faibles observées pendant la crise sanitaire qui tiraient la moyenne vers le bas.

La dispersion est également réduite. L'écart-type de la série corrigée est d'environ 3,1 millions de passagers contre près de 4 millions sur la série brute. La correction des points atypiques diminue donc la volatilité apparente de la série même s'il y a toujours une variabilité importante. Cette variabilité s'explique surtout par la tendance de long terme et par les mouvements saisonniers du trafic aérien.

Les valeurs extrêmes sont désormais moins influencées par les chocs exceptionnels. Le minimum de la série corrigée est d'environ 9,85 millions de passagers, tandis que le maximum atteint environ 23,96 millions. L'amplitude reste donc importante mais elle correspond plus à des variations structurelles ou saisonnières qu'à des ruptures isolées.

La forme de la distribution reste assez régulière. Le coefficient d'asymétrie est positif mais limité, avec une valeur d'environ 0,44, ce qui indique une légère concentration vers les valeurs élevées. Le coefficient de kurtosis d'environ 3 suggère une distribution moins extrême que celle de la série brute.

Le test de Shapiro-Wilk rejette l'hypothèse de normalité avec une p-value inférieure à 5 %. Cette non-normalité n'est pas surprenante pour une série temporelle mensuelle marquée par une tendance et une saisonnalité car les observations ne sont pas indépendantes et identiquement distribuées.

Le boxplot et l'histogramme de la série corrigée confirment cette lecture (Annexe B.4). La distribution apparaît plus régulière que celle de la série brute mais elle conserve des écarts importants entre les mois. Cela confirme la nécessité d'étudier plus précisément la saisonnalité dans la suite du dossier.

1.4 Mise en évidence de la saisonnalité

Après la correction des points atypiques, j'ai étudié la saisonnalité de la série corrigée. Cette étape est importante car le trafic aérien dépend fortement du mois de l'année, notamment des périodes de vacances et de la mobilité touristique.

L'observation de la série corrigée suggère déjà une saisonnalité annuelle. Les fluctuations se répètent globalement d'une année à l'autre, avec des niveaux plus élevés pendant les mois d'été et des niveaux plus faibles durant certaines périodes hivernales.

L'ACF confirme cette première impression (Annexe B.5). Elle présente une décroissance lente, ce qui suggère une dynamique persistante et une possible absence de stationnarité. Des pics apparaissent également aux retards saisonniers, notamment aux lags 12 et 24, ce qui indique que les valeurs d'un mois donné sont liées aux valeurs observées au même mois des années précédentes.

La PACF met aussi en évidence des dépendances de court terme entre les observations successives (Annexe B.6). Ces résultats justifient l'utilisation future de modèles capables de prendre en compte à la fois la dynamique temporelle et la saisonnalité (comme les modèles SARIMA).

La décomposition classique de la série corrigée confirme cette structure (Annexe B.7). Elle fait apparaître une tendance de long terme, une composante saisonnière régulière et une composante irrégulière plus limitée. La saisonnalité apparaît donc comme une caractéristique importante de la série.

Le périodogramme confirme également la présence d'une saisonnalité :

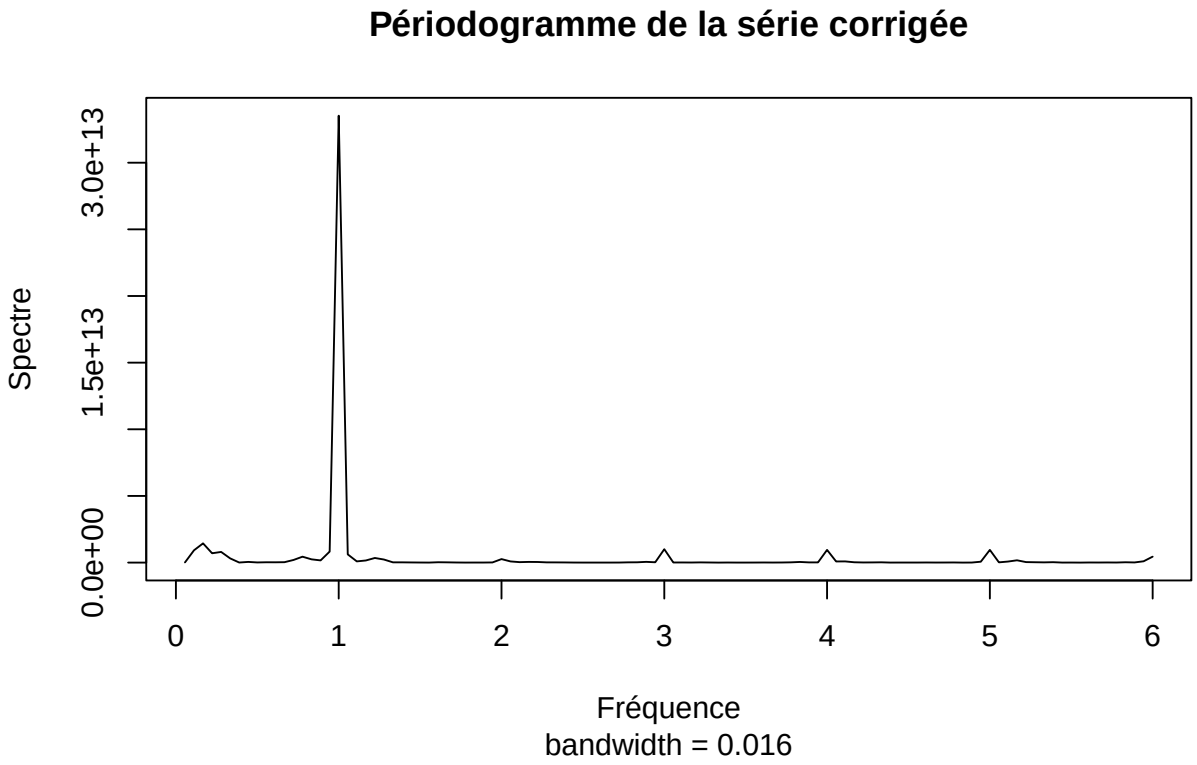


Figure 2: Périodogramme de la série corrigée

Il met en évidence un pic important à une fréquence saisonnière, ce qui indique que certaines fluctuations reviennent de manière régulière. Ce résultat est cohérent avec l'analyse graphique et avec les autocorrélations.

Enfin, les tests QS et Kruskal-Wallis confirment statistiquement cette saisonnalité.

Table 3: Tests statistiques de saisonnalité

Test	Statistique	p-value	Conclusion
QS	314.372	$< 0{,}001$	Saisonnalité significative
Kruskal-Wallis	100.944	$< 0{,}001$	Saisonnalité significative

Le test QS donne une statistique égale à 314,37 avec une p-value inférieure à 0,001. Le test de Kruskal-Wallis donne également une p-value inférieure à 0,001. Dans les deux cas, on rejette l'hypothèse d'absence de saisonnalité.

L'ensemble des résultats va donc vers la même conclusion, que la série corrigée présente une saisonnalité annuelle marquée. Cette structure devra être prise en compte dans la désaisonnalisation et dans les modèles de prévision.

1.5 Désaisonnalisation et décomposition X13-SARIMA-SEATS

Après avoir confirmé la présence d'une saisonnalité annuelle, j'ai désaisonnalisé la série corrigée avec la méthode X13-SARIMA-SEATS. L'objectif est d'isoler la tendance, la composante saisonnière, la composante irrégulière et la série corrigée des variations saisonnières.

La petite synthèse du modèle X13 confirme les principales caractéristiques observées dans les parties précédentes.

Table 4: Synthèse du modèle X13-SARIMA-SEATS

Élément	Résultat
Modèle RegARIMA retenu	ARIMA(1,1,1)(0,1,1)[12]
Transformation	Logarithmique
Schéma de décomposition	Multiplicatif
Effet de Pâques	Significatif
Outliers intégrés	Oui, autour de 2020-2021
Test de Ljung-Box sur les résidus	p-value = 0.3504

Le modèle retenu est un ARIMA(1,1,1)(0,1,1)[12] (Annexe C.1). Les différenciations régulière et saisonnière confirment que la série n'est pas stationnaire en niveau et qu'elle doit être corrigée à la fois de sa tendance et de sa saisonnalité. Les coefficients AR(1) (`Phi(1)`), MA(1) (`Theta(1)`) et le terme saisonnier MA(1) (`BTheta(1)`) sont significatifs, ce qui confirme la présence d'une dynamique temporelle et d'une dépendance saisonnière.

Le modèle retient également un effet de Pâques significatif, ainsi que plusieurs points atypiques autour de 2020 et 2021. Ces éléments sont cohérents avec la série étudiée car le trafic aérien dépend des périodes de mobilité, des effets de calendrier et des perturbations exceptionnelles liées à la crise sanitaire.

Le test de transformation conduit à retenir une transformation logarithmique (Annexe C.2). La différence d'AIC est négative (égale à -2), ce qui mène à privilégier une représentation multiplicative. Cette décision est cohérente avec la série car lorsque le niveau du trafic augmente, l'amplitude des variations saisonnières tend également à augmenter.

La décomposition X13 permet ensuite de visualiser la série corrigée, la série désaisonnalisée et la tendance.

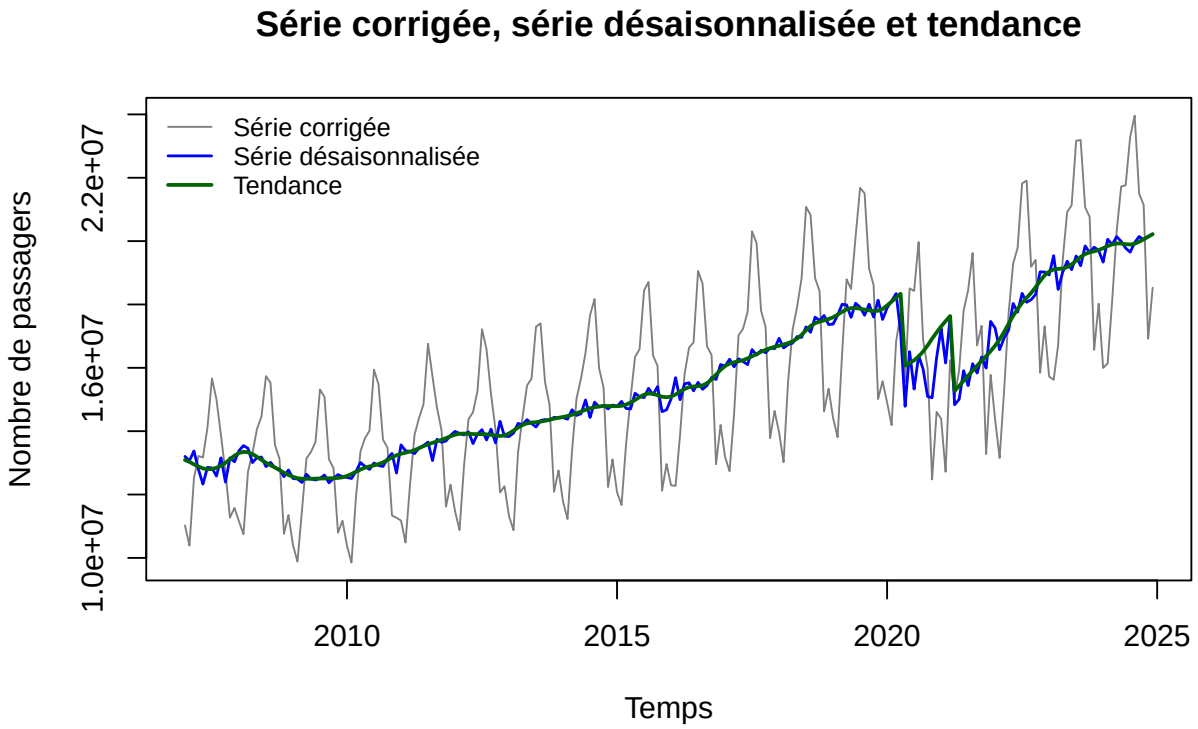


Figure 3: Décomposition X13-SARIMA-SEATS de la série corrigée

La série désaisonnalisée est plus lisse que la série corrigée car les fluctuations saisonnières ont été retirées. La tendance montre une progression du trafic aérien jusqu'en 2019, une rupture nette autour de la crise sanitaire, puis une reprise progressive. Cela confirme que le trafic aérien suit une dynamique de long terme mais reste très sensible aux chocs exceptionnels.

La composante saisonnière reste régulière et stable dans le temps. Elle confirme le schéma déjà observé, des niveaux plus élevés pendant les mois d'été et des niveaux plus faibles sur certaines périodes hivernales. La proximité entre la série désaisonnalisée et la tendance suggère que la composante irrégulière reste globalement limitée, même si la rupture de 2020 reste visible.

Enfin, les diagnostics des résidus ne montrent pas de problème majeur (Annexe C.3). Le test de Ljung-Box donne une p-value d'environ 0,3504, supérieure au seuil de 5 %. On ne rejette donc pas l'hypothèse d'absence d'autocorrélation résiduelle. Le modèle semble ainsi capter correctement la structure principale de la série.

Cette désaisonnalisation confirme donc que la série combine une tendance de long terme, une saisonnalité annuelle forte, des effets de calendrier et des chocs exceptionnels. Ces éléments devront être pris en compte dans la partie prévision.

2. Prévision de la série

Après avoir analysé la structure de la série, l'objectif est maintenant de produire des prévisions du trafic aérien commercial mensuel. Comme la série présente une saisonnalité annuelle marquée, les modèles utilisés doivent être capables de reproduire les variations régulières observées d'un mois à l'autre. La prévision est réalisée sur un horizon de 12 mois, afin d'obtenir des valeurs prévues pour l'année 2025.

Les prévisions sont effectuées sur la série saisonnière et non sur la série désaisonnalisée. En effet, l'objectif est de prévoir le trafic effectivement attendu mois par mois et avec ses variations saisonnières. De plus, comme la série étudiée est saisonnière, la méthode naïve retenue comme point de comparaison est une méthode naïve saisonnière.

2.1 Méthodes de référence : naïve saisonnière, X13, STL, STS

Dans un premier temps, j'ai estimé plusieurs méthodes de référence (la méthode naïve saisonnière, X13-SARIMA-SEATS, STL et STS). Elles permettent d'obtenir une première base de comparaison avant d'étudier des modèles plus avancés.

La méthode naïve saisonnière sert de benchmark. Elle reprend les niveaux observés à la même période l'année précédente. Pour 2025, elle prévoit par exemple environ 16,0 millions de passagers en janvier, 23,96 millions en août et 18,53 millions en décembre. Elle reproduit donc bien le profil annuel de la série, avec un pic pendant l'été, mais elle ne prolonge pas réellement la tendance au-delà de la dernière année observée (Annexe D.1).

Les prévisions obtenues avec X13-SARIMA-SEATS conservent également une saisonnalité marquée. Les niveaux les plus faibles sont prévus en début d'année et en novembre, tandis que les niveaux les plus élevés apparaissent pendant l'été. X13 prévoit par exemple environ 16,6 millions de passagers en janvier 2025 et 24,8 millions en août 2025. La trajectoire prévue reste donc cohérente avec la tendance récente et avec la structure saisonnière observée dans l'analyse exploratoire (Annexe D.2).

La méthode STL donne aussi un profil saisonnier cohérent. Les prévisions sont d'environ 17,5 millions de passagers en janvier 2025 et 23,3 millions en août 2025. La trajectoire prévue suit le schéma attendu avec un trafic plus faible en début d'année, une hausse progressive jusqu'à l'été, puis une baisse en fin d'année (Annexe D.3).

Enfin, le modèle STS produit des prévisions proches de celles des autres méthodes de référence. Il prévoit environ 16,9 millions de passagers en janvier 2025 et 24,2 millions en août 2025. Ce résultat confirme que la série est principalement portée par un niveau évolutif et une forte saisonnalité (Annexe D.4).

Dans l'ensemble, ces quatre méthodes produisent des prévisions cohérentes entre elles. Toutes conservent une saisonnalité annuelle nette, avec un pic estival et des niveaux plus faibles en

hiver. La méthode naïve saisonnière constitue le benchmark, alors que X13, STL et STS permettent d'intégrer davantage la structure de la série.

2.2 Méthodes de lissage exponentiel : Holt-Winters, ETS, TBATS, ADAM

Après les méthodes de référence, j'ai estimé plusieurs modèles de lissage exponentiel (Holt-Winters, ETS, TBATS et ADAM). L'objectif est de vérifier si des modèles fondés sur le lissage du niveau, de la tendance et de la saisonnalité permettent d'obtenir des prévisions satisfaisantes du trafic aérien commercial.

Le modèle Holt-Winters estime les paramètres suivants : $\alpha = 0{,}4922$, $\beta = 0{,}0033$ et $\gamma = 0{,}0001$. Le paramètre α étant assez élevé, le modèle ajuste le niveau de la série à partir des observations récentes. En revanche, les paramètres β et γ sont très proches de zéro ce qui signifie que la tendance et la saisonnalité restent presque inchangées dans le modèle. Le modèle conserve ainsi une structure assez stable, ce qui est cohérent avec la saisonnalité régulière du trafic aérien (Annexe E.1).

Le modèle ETS donne des résultats proches : $\alpha = 0{,}4065$, $\beta = 0{,}0085$, $\gamma = 0{,}0001$ et $\phi = 0{,}9761$. Le niveau s'ajuste sans réagir de manière excessive, la tendance reste stable et la saisonnalité est peu modifiée au cours du temps. Le paramètre d'amortissement ϕ, proche de 1 indique une tendance persistante (Annexe E.2).

Le modèle TBATS produit également des prévisions cohérentes avec le profil saisonnier attendu, avec des niveaux plus faibles en début d'année et un pic durant l'été. Toutefois, son AIC est égal à 6864,542, ce qui reste supérieur à celui d'ADAM (Annexe E.3).

Enfin, le modèle ADAM estime $\alpha = 0{,}4178$, $\beta = 0{,}0000$ et $\gamma = 0{,}0933$. Le niveau reste assez réactif, la tendance n'est quasiment pas actualisée, tandis que la composante saisonnière est davantage ajustée que dans Holt-Winters et ETS. Cela peut être pertinent pour une série où la saisonnalité est forte, même si elle reste régulière (Annexe E.4).

Table 5: Critères d'information des modèles de lissage exponentiel

Modèle	AIC	AICc	BIC
ADAM	6 276,641	6 276,831	6 290,143
ETS	6 843,232	6 846,704	6 903,987
TBATS	6 864,542	-	-
Holt-Winters	6 913,893	6 916,983	6 971,272

D'après ces critères, ADAM obtient le meilleur résultat parmi les méthodes de lissage exponentiel, avec l'AIC, l'AICc et le BIC les plus faibles. Il est suivi par ETS, TBATS puis Holt-Winters selon l'AIC. Ce classement donne une première indication sur l'ajustement des modèles mais il devra être confirmé par l'évaluation out-of-sample, car ces critères évaluent

l'ajustement des modèles sur la période d'estimation mais ils ne permettent pas à eux seuls de conclure sur la qualité prédictive.

2.3 Modèles SARIMA : automatique, manuel et SSARIMA

Après les méthodes de référence et les méthodes de lissage exponentiel, j'ai estimé trois modèles de type SARIMA (un SARIMA automatique, un SARIMA manuel et un SSARIMA). Ces modèles sont adaptés à la série car ils permettent de tenir compte de la dynamique temporelle et de la saisonnalité annuelle.

Le SARIMA automatique retient une structure ARIMA(2,0,0)(0,1,2)[12] avec drift (Annexe F.1). La différenciation saisonnière $D = 1$ confirme la prise en compte de la saisonnalité annuelle, tandis que l'absence de différenciation non saisonnière indique que la tendance est principalement captée par le drift. Les coefficients AR(1), AR(2), SMA(1) et SMA(2) sont respectivement d'environ 0,4079, 0,4248, -0,2369 et -0,4929. Le drift positif, d'environ 33 708, traduit une dynamique moyenne croissante du trafic aérien.

J'ai ensuite estimé un SARIMA manuel de structure ARIMA(1,1,1)(0,1,1)[12] (Annexe F.2). Ce choix reprend la structure identifiée lors de la désaisonnalisation X13. Il permet de prendre en compte une différenciation régulière, une différenciation saisonnière et une dépendance saisonnière à 12 mois. Les coefficients AR(1), MA(1) et SMA(1) sont respectivement d'environ -0,3153, -0,2519 et -0,4453, ils indiquent que le modèle tient compte à la fois des dépendances de court terme et des effets saisonniers.

Enfin, j'ai estimé un modèle SSARIMA à partir de la série désaisonnalisée obtenue avec X13 (Annexe F.3). Le modèle retenu sur cette série est un ARIMA(0,1,1) avec drift. Le coefficient MA(1), d'environ -0,5057, et le drift positif, d'environ 33 013, indiquent que la série désaisonnalisée conserve une dynamique moyenne croissante. Cette approche est plus simple, mais elle dépend de la qualité de la re-saisonnalisation effectuée ensuite.

Table 6: Critères d'information des modèles SARIMA

Modèle	Spécification	AIC	AICc
SARIMA automatique	ARIMA(2,0,0)(0,1,2)[12] avec drift	5 946,857	5 947,283
SARIMA manuel	ARIMA(1,1,1)(0,1,1)[12]	5 958,497	5 958,699
SSARIMA	ARIMA(0,1,1) avec drift	6 194,643	6 194,756

D'après ces critères, le SARIMA automatique obtient le meilleur ajustement en échantillon, avec l'AIC et l'AICc les plus faibles. Il est suivi par le SARIMA manuel, tandis que le SSARIMA présente un ajustement moins favorable. Les trois modèles restent toutefois cohérents avec les caractéristiques de la série, puisqu'ils prennent en compte la tendance, la dépendance temporelle et la saisonnalité annuelle. Ce classement devra être confirmé par

l'évaluation out-of-sample car un bon ajustement aux données passées ne garantit pas nécessairement la meilleure qualité prédictive.

3. Comparaison des modèles estimés

Après avoir estimé les différentes familles de modèles, je compare leurs résultats afin d'identifier les spécifications qui semblent les plus pertinentes pour la série étudiée. Cette première comparaison s'appuie sur les paramètres estimés et sur les critères d'information, principalement l'AIC et l'AICc. Ces indicateurs permettent d'évaluer l'ajustement des modèles tout en pénalisant les spécifications trop complexes.

Cette lecture doit cependant rester prudente. Les critères d'information portent sur la période d'estimation donc ils donnent une indication sur l'ajustement aux données passées mais ne suffisent pas à choisir définitivement le meilleur modèle de prévision. C'est pourquoi cette comparaison sera complétée ensuite par une évaluation out-of-sample.

3.1 Paramètres estimés et critères d'information

Le tableau de synthèse des modèles estimés permet de comparer les principales spécifications retenues, leurs paramètres et leurs critères d'information.

Table 7: Comparaison des modèles selon les critères AIC et AICc

Modèle	AIC	AICc
SARIMA automatique	5 946,857	5 947,283
SARIMA manuel	5 958,497	5 958,699
SSARIMA	6 194,643	6 194,756
ADAM	6 276,641	6 276,831
ETS	6 843,232	6 846,704
TBATS	6 864,542	-
Holt-Winters	6 913,893	6 916,983

Table 8: Critères retenus pour les méthodes de référence

Modèle	Critère	Résultat
Naïve saisonnière	Benchmark	Référence
X13-SARIMA-SEATS	MSE / R^2 OOS	187 939 518 281 / 0,589
STL	MSE / R^2 OOS	596 266 870 822 / -0,304
STS	MSE / R^2 OOS	186 939 111 927 / 0,591

Dans l'ensemble, les modèles estimés confirment les résultats de l'analyse exploratoire. La série présente une tendance de long terme, une dynamique persistante et une saisonnalité annuelle marquée.

La comparaison par AIC/AICc concerne surtout les modèles estimés dans un cadre directement comparable. Parmi les méthodes de lissage exponentiel, ADAM obtient les critères d'information les plus faibles, avec un AIC d'environ 6276,641 et un AICc d'environ 6276,831. Il se distingue donc de Holt-Winters, ETS et TBATS dans cette famille de modèles.

Les modèles SARIMA présentent les meilleurs critères parmi les modèles classiques. Le SARIMA automatique arrive en première position, avec un AIC d'environ 5946,857 et un AICc d'environ 5947,283. Il est suivi par le SARIMA manuel, dont l'AIC reste proche, à environ 5958,497. Le SSARIMA obtient des critères plus élevés ce qui suggère un ajustement moins favorable en échantillon.

Les méthodes de référence ne sont pas toutes comparables à partir des critères d'information. La méthode naïve saisonnière sert surtout de benchmark, tandis que X13-SARIMA-SEATS, STL et STS sont davantage comparés à partir de leurs performances out-of-sample. Le tableau complémentaire montre que parmi ces méthodes, STS et X13 obtiennent de bons résultats avec des R^2 OOS respectifs de 0,591 et 0,589, alors que STL obtient un R^2 OOS négatif.

Ainsi, les critères d'information conduisent d'abord à privilégier le SARIMA automatique parmi les modèles classiques, puis le SARIMA manuel. Parmi les modèles de lissage exponentiel, ADAM ressort comme le plus performant. Cette première hiérarchie reste cependant provisoire car elle devra être complétée par la comparaison graphique des prévisions puis par l'évaluation out-of-sample.

3.2 Comparaison graphique des prévisions

Après la comparaison des paramètres et des critères d'information, j'ai comparé graphiquement les prévisions produites par les différents modèles. Cette étape permet de vérifier si les modèles donnent des trajectoires cohérentes avec la dynamique observée de la série, notamment avec sa tendance et sa saisonnalité. Elle permet aussi d'identifier visuellement les modèles qui produisent des prévisions trop élevées, trop faibles ou trop éloignées du profil saisonnier habituel.

Le graphique de comparaison des prévisions montre que la plupart des modèles conservent une structure saisonnière très marquée.

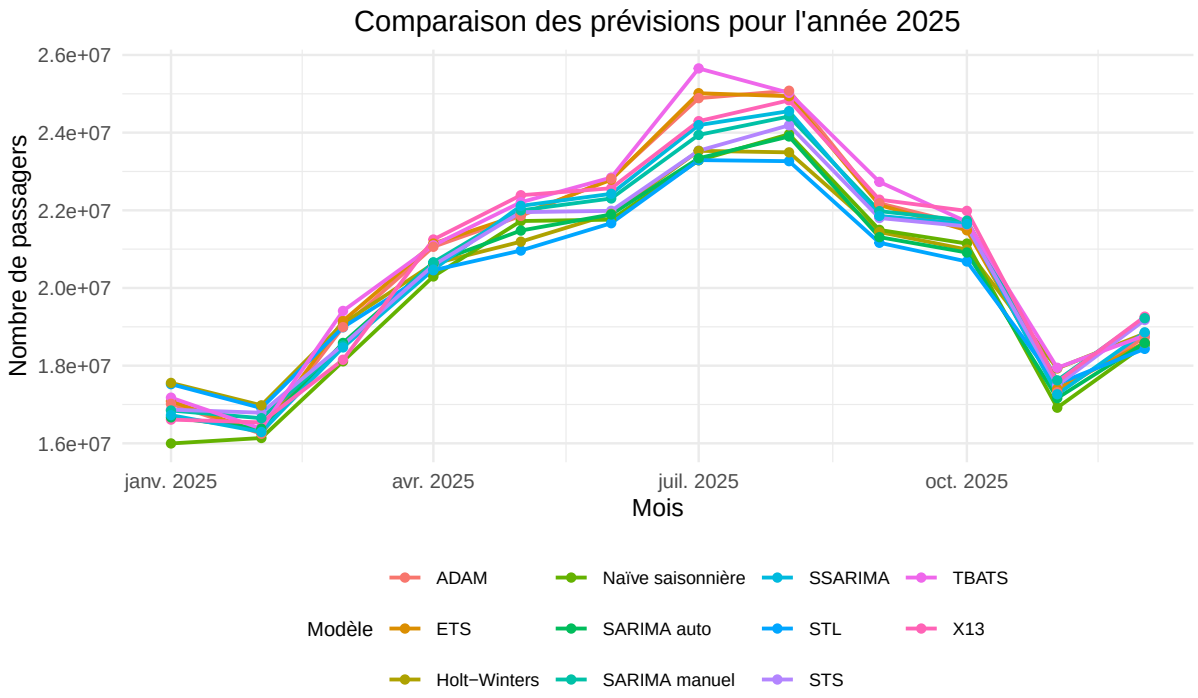


Figure 4: Comparaison des prévisions des différents modèles

Les prévisions présentent globalement le même profil annuel, on voit des niveaux plus faibles en début d'année, une hausse progressive au printemps, un pic pendant les mois d'été, puis une baisse en fin d'année. Ce profil est cohérent avec les résultats de l'analyse exploratoire qui avaient aussi montré une forte saisonnalité du trafic aérien commercial.

Les méthodes de référence donnent des trajectoires relativement proches. La méthode naïve saisonnière reprend le profil observé l'année précédente, tandis que X13, STL et STS produisent des prévisions légèrement plus lissées. Toutes conservent toutefois le pic estival et les niveaux plus faibles en hiver.

Les méthodes de lissage exponentiel reproduisent également la saisonnalité annuelle, mais avec quelques différences de niveau. ADAM, qui présentait les meilleurs critères dans cette famille de modèles, produit une trajectoire cohérente avec la dynamique récente de la série. Holt-Winters, ETS et TBATS restent proches, même si leurs critères d'information étaient moins favorables.

Les modèles SARIMA donnent aussi des prévisions compatibles avec le profil saisonnier attendu. Le SARIMA automatique et le SARIMA manuel suivent des trajectoires proches, tandis que le SSARIMA conserve les variations mensuelles après la re-saisonnalisation.

Globalement, aucun modèle ne produit de trajectoire totalement incohérente. Les différences portent surtout sur le niveau moyen prévu et sur l'ampleur des variations saisonnières (Annexe

G.1). Cette comparaison visuelle reste toutefois insuffisante pour choisir le meilleur modèle alors on va la compléter par une évaluation quantitative des erreurs de prévision.

4. Évaluation out-of-sample des prévisions

Après la comparaison en échantillon des modèles estimés, j'ai évalué leur qualité prédictive en dehors de l'échantillon d'estimation. Cette étape est essentielle car un modèle peut très bien s'ajuster aux données passées sans être le plus performant pour prévoir de nouvelles observations. L'évaluation out-of-sample permet donc de comparer les modèles dans une situation plus proche d'un exercice réel de prévision.

Dans cette partie, les modèles sont comparés à partir des erreurs de prévision calculées sur la période de test. Les critères retenus sont le MSE, le R^2 OOS et le CSPE. Le MSE mesure l'erreur quadratique moyenne (plus il est faible, plus le modèle est précis). Le R^2 OOS mesure la performance du modèle par rapport au modèle de référence naïf (lorsqu'il est positif, le modèle fait mieux que le benchmark et lorsqu'il est négatif, il fait moins bien). Enfin, le CSPE permet d'observer l'accumulation des erreurs de prévision au cours du temps.

4.1 MSE et R^2 OOS

Le tableau des performances out-of-sample met en évidence des différences importantes entre les modèles.

Table 9: Performances out-of-sample des modèles

Modèle	MSE	R^2 OOS
SARIMA manuel	178 891 211 416	0,609
STS	186 939 111 927	0,591
X13-SARIMA-SEATS	187 939 518 281	0,589
ADAM	257 749 571 552	0,436
SSARIMA	276 551 799 323	0,395
TBATS	293 566 258 813	0,358
ETS	320 739 013 392	0,298
SARIMA automatique	350 777 289 015	0,233
Holt-Winters	420 481 601 590	0,080
Naïve saisonnière	457 212 516 653	-
STL	596 266 870 822	-0,304

Le SARIMA manuel obtient le MSE le plus faible, avec une valeur d'environ 178,9 milliards. Il s'agit donc du modèle le plus précis selon ce critère. Il est suivi par le modèle STS, puis par X13-SARIMA-SEATS, qui présentent également de bonnes performances prédictives.

Le R^2 OOS confirme ce classement. Le SARIMA manuel obtient la valeur la plus élevée, avec un R^2 OOS d'environ 0,61. Cela signifie qu'il réduit l'erreur de prévision d'environ 61 % par rapport à la méthode naïve saisonnière. Ce résultat montre que le modèle manuel améliore réellement la qualité de prévision par rapport au benchmark.

Les modèles STS et X13-SARIMA-SEATS restent aussi nettement meilleurs que le modèle naïf. Ils semblent donc bien capter les principales caractéristiques de la série, notamment la tendance, la saisonnalité et la dynamique temporelle.

Les méthodes de lissage exponentiel présentent des résultats plus intermédiaires. ADAM est le meilleur modèle de cette famille, avec un MSE inférieur à ceux de TBATS, ETS et Holt-Winters. Cependant, il reste moins performant que les meilleurs modèles SARIMA ou structurels.

Le modèle STL se distingue négativement, avec un R^2 OOS d'environ -0,30. Il fait donc moins bien que la méthode naïve saisonnière, malgré une trajectoire de prévision visuellement cohérente.

Ainsi, l'analyse du MSE et du R^2 OOS conduit à privilégier le SARIMA manuel. Contrairement à la comparaison en échantillon, où le SARIMA automatique obtenait les meilleurs critères d'information, l'évaluation out-of-sample montre que le modèle manuel offre la meilleure précision prédictive.

4.2 Erreurs cumulées de prévision : CSPE

Pour compléter l'analyse, j'ai étudié les erreurs cumulées de prévision à l'aide du CSPE. Le CSPE correspond au cumul des erreurs de prévision au carré sur la période de test (Annexe H.1). Pour lire ce graphique, on dit que plus la courbe est basse, plus le modèle accumule peu d'erreurs, et donc plus il est performant.

Le graphique du CSPE confirme les résultats obtenus avec le MSE et le R^2 OOS.

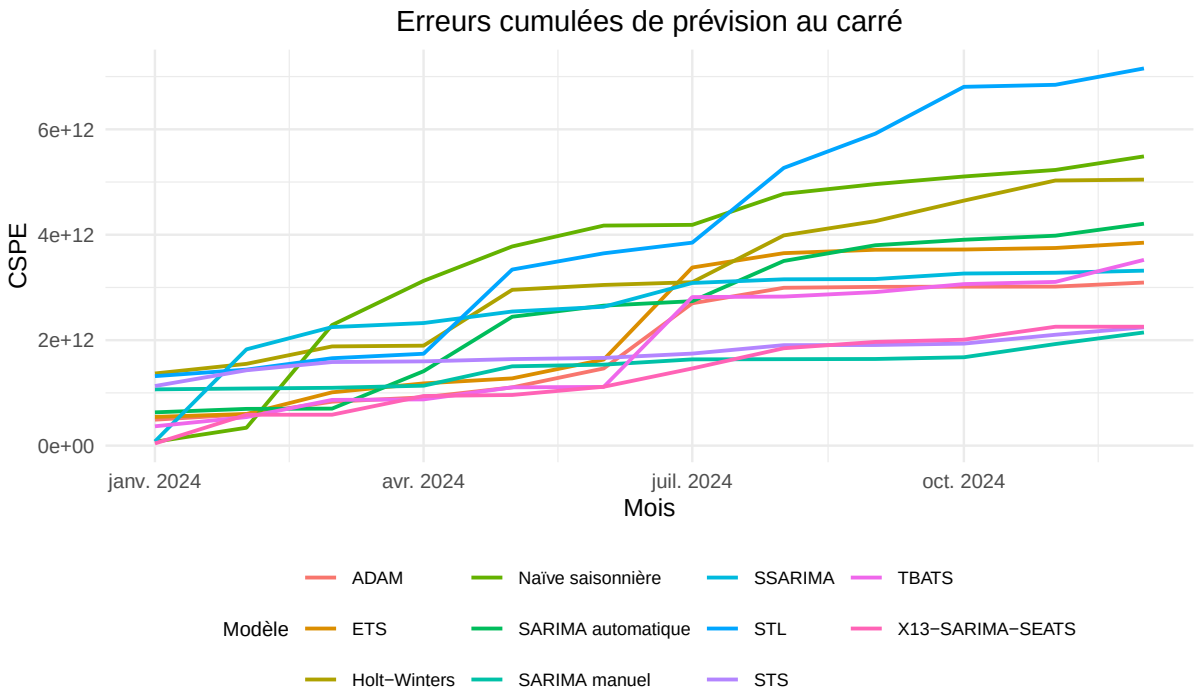


Figure 5: Erreurs cumulées de prévision au carré par modèle

Les modèles les plus performants sont donc ceux dont la courbe augmente le plus lentement. Le SARIMA manuel présente la trajectoire la plus favorable, car il accumule moins d'erreurs que les autres modèles sur l'ensemble de la période de test. Cela confirme sa bonne capacité à prévoir le trafic aérien mois par mois.

À l'inverse, le modèle STL présente une accumulation d'erreurs plus importante. Sa courbe de CSPE est plus élevée, ce qui confirme qu'il est moins performant en prévision. Ce résultat est cohérent avec son R^2 OOS négatif, le modèle STL ne parvient pas à améliorer la prévision par rapport au benchmark naïf saisonnier.

Les modèles STS et X13-SARIMA-SEATS se situent parmi les modèles les plus performants. Leurs courbes de CSPE restent relativement basses, ce qui montre qu'ils produisent des erreurs limitées sur la période de test. Cela confirme que les modèles capables de combiner tendance, saisonnalité et dynamique temporelle sont les plus adaptés à la série du trafic aérien commercial.

Les méthodes de lissage exponentiel occupent une position intermédiaire. ADAM est toujours le meilleur modèle de cette famille, mais sa courbe de CSPE reste moins favorable que celle du SARIMA manuel. ETS, TBATS et Holt-Winters accumulent davantage d'erreurs, ce qui confirme leur performance plus limitée en comparaison des modèles SARIMA et structurels.

4.3 Sélection du meilleur modèle

L'ensemble des critères out-of-sample conduit à retenir le SARIMA manuel comme meilleur modèle de prévision. Il obtient le MSE le plus faible, le R^2 OOS le plus élevé et une trajectoire de CSPE favorable. Il prévoit donc le plus précisément le trafic aérien commercial mensuel sur la période de test.

Ce résultat est intéressant, car le SARIMA manuel n'était pas le meilleur modèle selon les critères d'information en échantillon. Le SARIMA automatique présentait un AIC plus faible mais il se révèle moins performant en prévision out-of-sample. Cela confirme qu'un bon ajustement aux données historiques ne garantit pas nécessairement la meilleure performance prédictive.

Le choix du SARIMA manuel reste cohérent avec la structure de la série. Ce modèle prend en compte la tendance, la saisonnalité annuelle et les dépendances temporelles de court terme. Les modèles STS et X13-SARIMA-SEATS constituent aussi de bonnes alternatives car ils obtiennent des résultats proches. En revanche, le modèle STL doit être écarté, car il est moins performant que le benchmark naïf saisonnier. Les méthodes de lissage exponentiel, notamment ADAM, peuvent rester utiles pour comparaison mais elles ne dominent pas les meilleurs modèles SARIMA ou structurels.

À ce stade, le SARIMA manuel apparaît donc comme le modèle le plus adapté pour prévoir la série. Ce choix sera complété par le test de Diebold-Mariano afin de vérifier si les différences de qualité prédictive entre les modèles sont statistiquement significatives.

5. Test de Diebold-Mariano

Après avoir comparé les modèles à partir des erreurs de prévision, j'ai utilisé le test de Diebold-Mariano afin de vérifier si les différences de performance prédictive sont statistiquement significatives. Cette étape va complèter l'analyse précédente, le MSE, le R^2 OOS et le CSPE permettent de classer les modèles selon leurs erreurs, alors que le test de Diebold-Mariano permet d'évaluer si ces écarts sont suffisamment importants pour conclure qu'un modèle prévoit significativement mieux qu'un autre.

5.1 Principe du test

Le test de Diebold-Mariano permet de comparer les erreurs de prévision de deux modèles sur une même période de test. Dans ce dossier, chaque modèle est comparé à la prévision d'un modèle AR(1). Le test est réalisé avec l'option "less", afin de vérifier si les pertes de prévision du modèle testé sont significativement plus faibles que celles du modèle AR(1). Ce choix est cohérent avec la série étudiée car le trafic aérien présente une saisonnalité annuelle marquée.

L'hypothèse nulle du test est que les deux modèles ont la même qualité prédictive. Lorsque la p-value est inférieure au seuil de 5 %, on rejette cette hypothèse et on considère que la différence de performance est statistiquement significative.

Le signe de la statistique de test permet ensuite d'interpréter le sens de la différence. Une statistique négative indique que le modèle testé présente des pertes de prévision plus faibles que le modèle AR(1), donc qu'il prévoit mieux que ce benchmark. À l'inverse, une statistique positive indique que le modèle testé accumule davantage d'erreurs.

5.2 Résultats

Les résultats du test de Diebold-Mariano montrent que la majorité des modèles présentent une différence significative par rapport au modèle AR(1).

Table 10: Résultats du test de Diebold-Mariano par rapport au modèle AR(1)

Modèle	Statistique DM	p-value	Conclusion
Holt-Winters	-4.785	$< 0{,}001$	Différence significative
SARIMA automatique	-4.780	$< 0{,}001$	Différence significative
STL	-4.703	$< 0{,}001$	Différence significative
STS	-4.701	$< 0{,}001$	Différence significative
SARIMA manuel	-4.525	$< 0{,}001$	Différence significative
X13-SARIMA-SEATS	-4.495	$< 0{,}001$	Différence significative
ETS	-4.458	$< 0{,}001$	Différence significative
ADAM	-4.431	$< 0{,}001$	Différence significative
TBATS	-4.264	$< 0{,}001$	Différence significative
SSARIMA	-0.335	0,3702	Différence non significative

La plupart des modèles ont une statistique de test négative et une p-value inférieure au seuil de 5 %. Cela signifie que leurs pertes de prévision sont significativement plus faibles que celles du modèle AR(1). Ces résultats confirment donc que plusieurs modèles apportent une amélioration statistiquement significative par rapport au benchmark AR(1).

Le SARIMA manuel présente une p-value inférieure à 5 %, ce qui confirme qu'il améliore significativement la prévision par rapport au modèle AR(1). Ce résultat est cohérent avec les critères out-of-sample étudiés précédemment puisque le SARIMA manuel obtenait le MSE le plus faible, le meilleur R^2 OOS et une trajectoire de CSPE favorable.

Les modèles STS et X13-SARIMA-SEATS sont également significativement meilleurs que le modèle AR(1). Cela confirme qu'ils constituent des alternatives solides même s'ils ne dominent pas le SARIMA manuel dans l'évaluation globale des performances prédictives.

Les méthodes de lissage exponentiel présentent elles aussi, pour la plupart, une amélioration significative par rapport au benchmark AR(1). Néanmoins leurs MSE et leurs R^2 OOS restent moins favorables que ceux des meilleurs modèles SARIMA ou structurels. Elles ne sont donc pas retenues comme modèles finaux.

Le résultat du modèle STL doit être nuancé. Le test de Diebold-Mariano indique une différence significative par rapport au modèle AR(1) mais les critères out-of-sample montrent que ce modèle obtient le MSE le plus élevé et un R^2 OOS négatif. Il n'est donc pas retenu comme modèle final, malgré le résultat du test.

Enfin, le modèle SSARIMA ne présente pas d'amélioration significative par rapport au modèle AR(1). Sa p-value élevée, égale à 0,3702, ne permet pas de rejeter l'hypothèse d'égalité de qualité prédictive avec le benchmark.

5.3 Conclusion statistique

Le test de Diebold-Mariano complète les résultats obtenus avec le MSE, le R^2 OOS et le CSPE. Il montre que plusieurs modèles améliorent significativement la prévision par rapport au modèle AR(1). Parmi eux, le SARIMA manuel confirme sa pertinence car il est significativement meilleur que le benchmark AR(1) et il présente également les meilleures performances out-of-sample.

Le choix du SARIMA manuel ne repose donc pas uniquement sur le test de Diebold-Mariano. Il repose surtout sur la convergence des critères de prévision avec le MSE le plus faible, le R^2 OOS le plus élevé et une trajectoire de CSPE favorable. Le test de Diebold-Mariano permet simplement de confirmer que cette amélioration par rapport au modèle AR(1) est statistiquement significative.

Les modèles STS et X13-SARIMA-SEATS restent de bonnes alternatives car ils obtiennent aussi de bons résultats et améliorent significativement la prévision par rapport au benchmark AR(1). En revanche, le modèle SSARIMA n'est pas retenu car son amélioration n'est pas statistiquement significative. Le modèle STL est aussi écarté car ses performances out-of-sample restent défavorables malgré un test significatif.

Pour conclure l'ensemble de l'analyse conduit à retenir le SARIMA manuel comme modèle final. Ce modèle est encore une fois cohérent avec les caractéristiques de la série puisqu'il prend en compte la tendance, la saisonnalité annuelle et les dépendances temporelles. Il offre également la meilleure qualité prédictive sur la période de test, ce qui justifie son choix pour prévoir le trafic aérien commercial mensuel en France.

CONCLUSION

Dans ce dossier, j'ai étudié l'évolution du trafic aérien commercial mensuel en France sur la période allant de janvier 2007 à décembre 2024. L'objectif était d'analyser la structure de cette série puis de comparer plusieurs méthodes de prévision afin d'identifier le modèle le plus adapté.

L'analyse exploratoire a d'abord montré que la série présente plusieurs caractéristiques importantes. Le trafic aérien suit une tendance globalement croissante jusqu'en 2019, puis connaît une rupture très marquée à partir de 2020 en raison de la crise sanitaire liée au COVID-19. La série présente également une forte saisonnalité annuelle, avec des niveaux plus élevés pendant les mois d'été et des niveaux plus faibles durant certains mois d'hiver. Cette saisonnalité a été confirmée par l'observation graphique, l'ACF, le périodogramme et les tests statistiques.

La détection des points atypiques a permis d'identifier plusieurs perturbations importantes, principalement concentrées autour de la période 2020-2021. Ces observations correspondent économiquement aux restrictions de déplacement, à la chute du trafic aérien pendant la crise sanitaire, puis à la reprise progressive de l'activité. La série a donc été corrigée afin de mieux analyser sa dynamique régulière. Les statistiques descriptives sur la série corrigée montrent un niveau moyen d'environ 15,5 millions de passagers par mois, avec une dispersion encore importante mais moins influencée par les valeurs extrêmes.

La désaisonnalisation par X13-SARIMA-SEATS a confirmé que la série combine une tendance de long terme, une saisonnalité annuelle forte, des effets calendaires et des chocs exceptionnels. La décomposition a permis d'isoler la tendance, la composante saisonnière et la composante irrégulière. Elle a aussi montré que la saisonnalité du trafic aérien est régulière et stable dans le temps ce qui a justifié l'utilisation de modèles capables de reproduire cette structure.

Dans la partie prévision, plusieurs familles de modèles ont été estimées. Tout d'abord les méthodes de référence puis les méthodes de lissage exponentiel et enfin les modèles SARIMA. Les prévisions obtenues sont globalement cohérentes avec la structure de la série car elles conservent un pic estival et des niveaux plus faibles en hiver. La comparaison des critères d'information a d'abord mis en avant le SARIMA automatique parmi les modèles classiques, ainsi que le modèle ADAM parmi les méthodes de lissage exponentiel. Toutefois, ces critères ne suffisent pas à sélectionner le meilleur modèle car ils évaluent surtout l'ajustement au sein de l'échantillon.

L'évaluation out-of-sample a permis de comparer les modèles sur leur véritable qualité prédictive. Les résultats montrent que le SARIMA manuel obtient le MSE le plus faible, le meilleur R^2 OOS et une trajectoire de CSPE favorable. Il améliore nettement la prévision par rapport à la méthode naïve saisonnière. Le test de Diebold-Mariano complète cette conclusion en montrant que le SARIMA manuel améliore aussi significativement la prévision par rapport au modèle AR(1), utilisé comme benchmark pour ce test.

Ainsi, le SARIMA manuel apparaît comme le modèle le plus adapté pour prévoir le trafic aérien commercial mensuel en France. Ce résultat est cohérent avec l'analyse de la série parce que ce modèle prend en compte à la fois la tendance, la saisonnalité annuelle et les dépendances temporelles de court terme. Les modèles STS et X13-SARIMA-SEATS constituent également de bonnes alternatives mais ils ne dominent pas le SARIMA manuel dans l'évaluation globale.

Ce travail montre enfin l'importance de ne pas choisir un modèle uniquement à partir de son ajustement en échantillon. Un modèle peut obtenir de bons critères d'information sans être le plus performant en prévision. Dans le cadre de cette étude, c'est l'évaluation out-of-sample, complétée par le test de Diebold-Mariano par rapport au modèle AR(1), qui permet de retenir le modèle final de manière plus rigoureuse. Le SARIMA manuel peut donc être utilisé pour produire une prévision de court terme du trafic aérien commercial mensuel, tout en gardant à l'esprit que cette série reste sensible aux chocs exceptionnels, notamment sanitaires, économiques ou géopolitiques.

ANNEXES

Annexe A — Préparation et présentation des données

Annexe A.1 — Construction de la base et de la série temporelle

Table 11: Vérifications de la série temporelle

Élément	Résultat
Début de la série	2007-1
Fin de la série	2024-12
Fréquence	12
Nombre d'observations	216
Valeurs manquantes	0

Annexe B — Analyse exploratoire complémentaire

Annexe B.1 — Boxplot de la série brute et détection simple par IQR

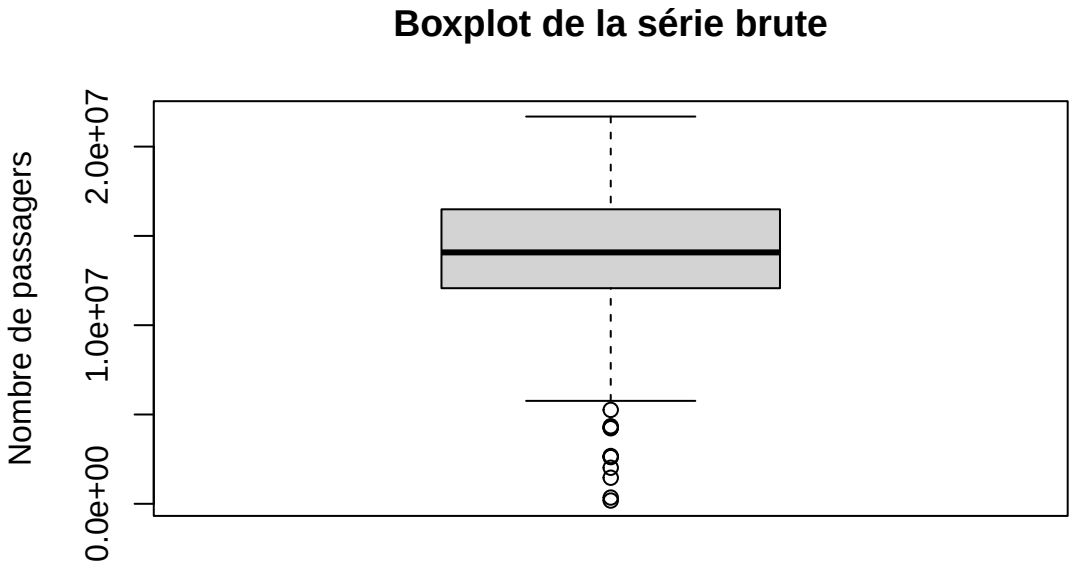


Figure 6: Boxplot de la série brute

Table 12: Valeurs atypiques détectées par la méthode IQR

Date	Nombre de passagers
avril 2020	182 431
mai 2020	349 753
juin 2020	1 459 968
octobre 2020	5 258 268
novembre 2020	2 019 221
décembre 2020	4 341 335
janvier 2021	4 258 346
février 2021	2 676 282
mars 2021	2 630 949
avril 2021	2 615 663
mai 2021	4 229 865

Annexe B.2 — Sortie complète de la détection des points atypiques avec tso()

Table 13: Sortie complète des points atypiques détectés par ‘tso()‘

type	ind	time	coefhat	tstat
AO	40	2010:04	-2 288 717	-7,231207
AO	93	2014:09	-1 621 758	-5,148420
LS	159	2020:03	-9 824 133	-21,047926
TC	160	2020:04	-7 695 144	-16,995169
AO	162	2020:06	-3 453 934	-8,661957
TC	171	2021:03	-3 635 527	-8,122183
LS	175	2021:07	4 057 187	10,044235
LS	179	2021:11	2 933 197	7,102219
TC	180	2021:12	-2 497 442	-5,784246
AO	181	2022:01	-2 058 088	-5,428399

Annexe B.3 — Comparaison entre série brute et série corrigée

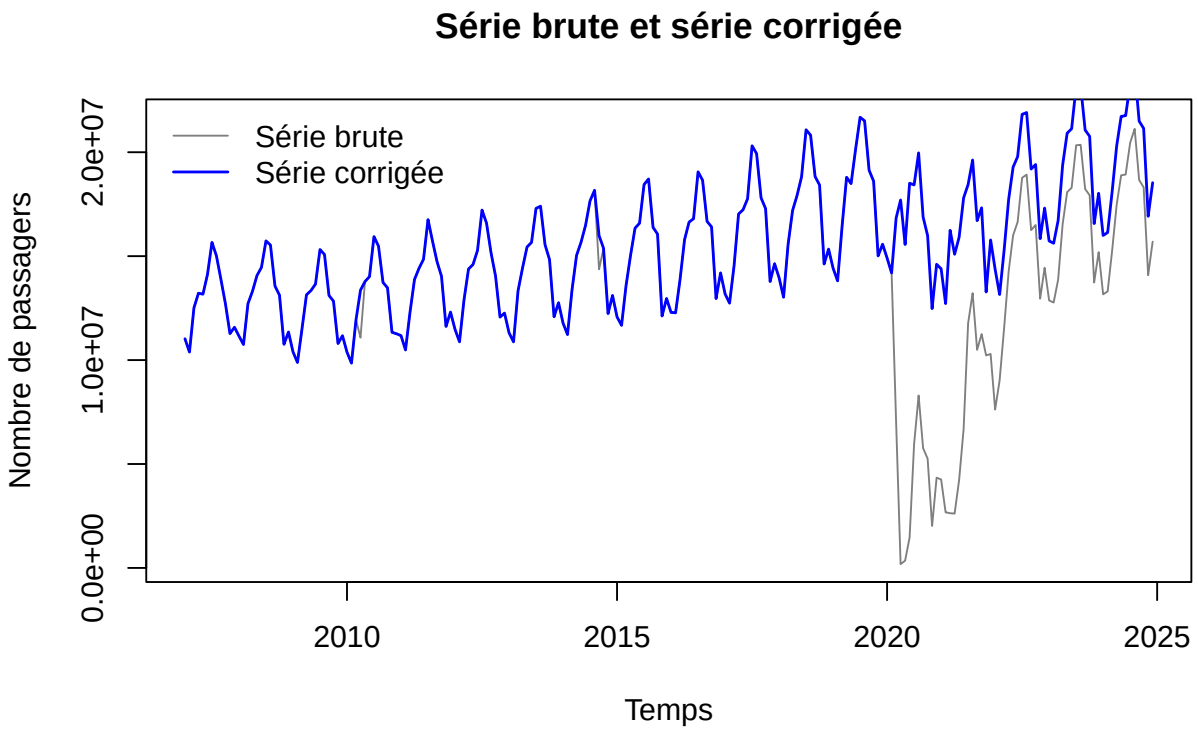


Figure 7: Comparaison entre la série brute et la série corrigée

Annexe B.4 — Boxplot et histogramme de la série corrigée

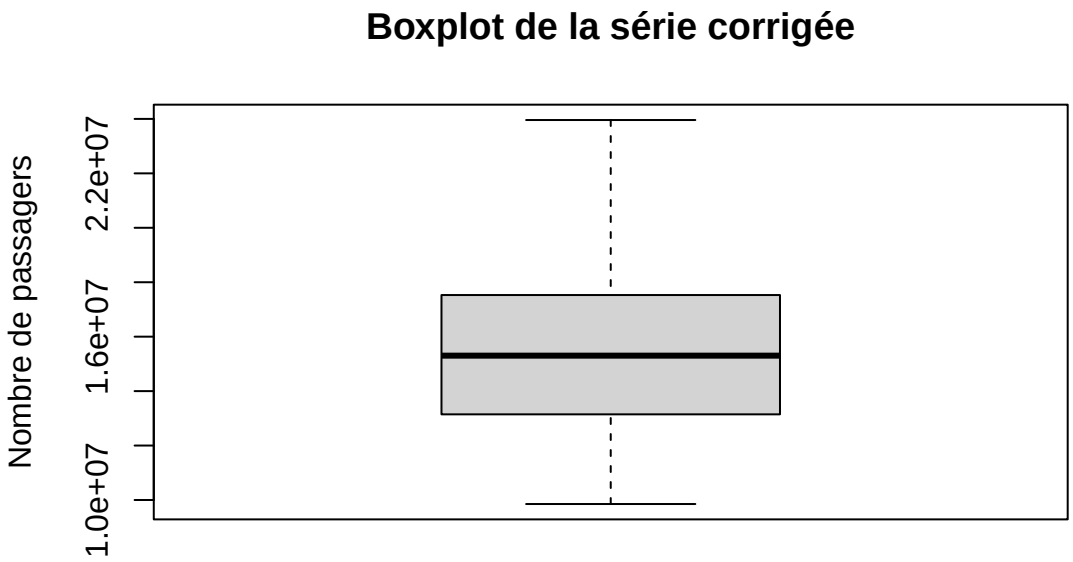


Figure 8: Boxplot de la série corrigée

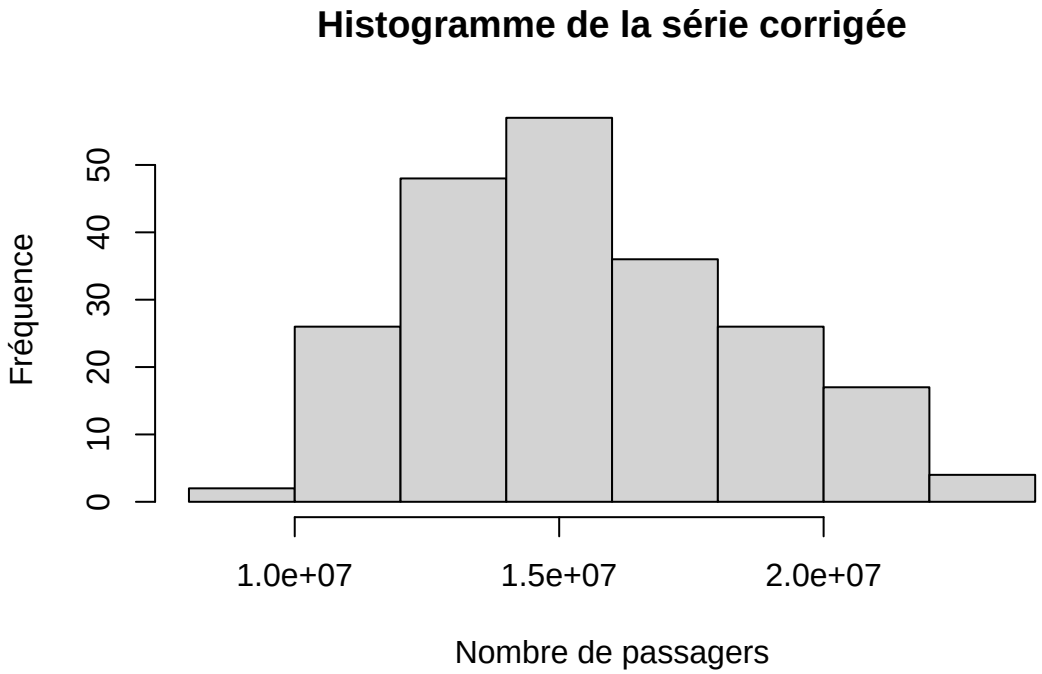


Figure 9: Histogramme de la série corrigée

Annexe B.5 — ACF de la série corrigée

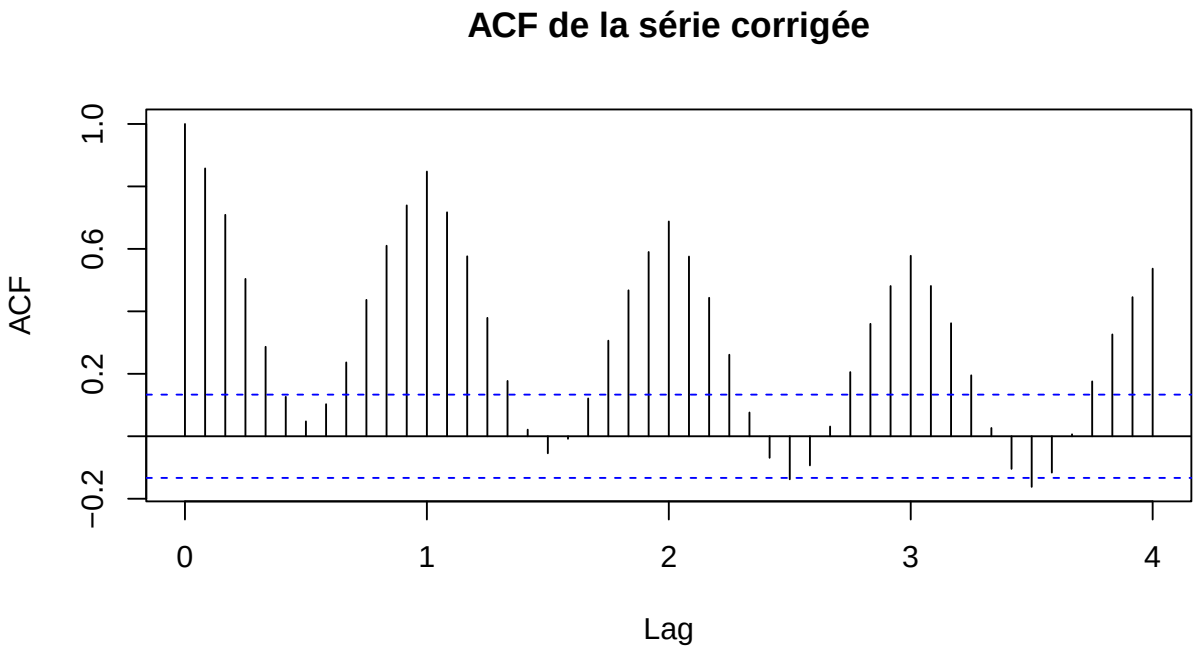


Figure 10: ACF de la série corrigée

Annexe B.6 — PACF de la série corrigée

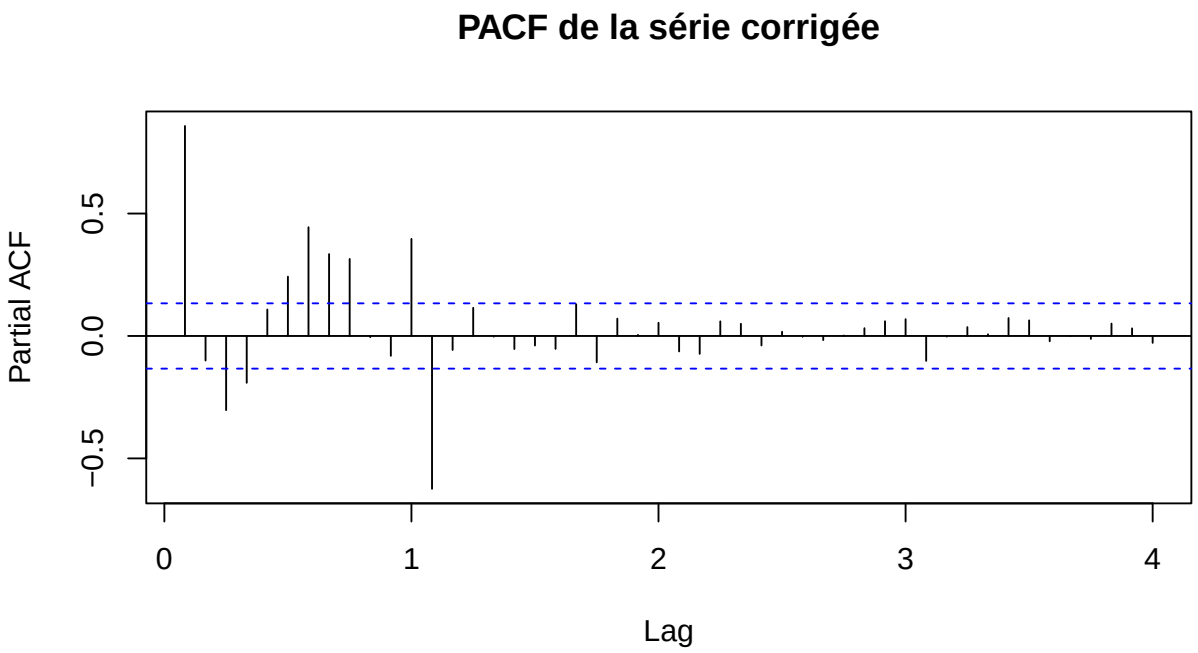


Figure 11: PACF de la série corrigée

Annexe B.7 — Décomposition classique de la série corrigée

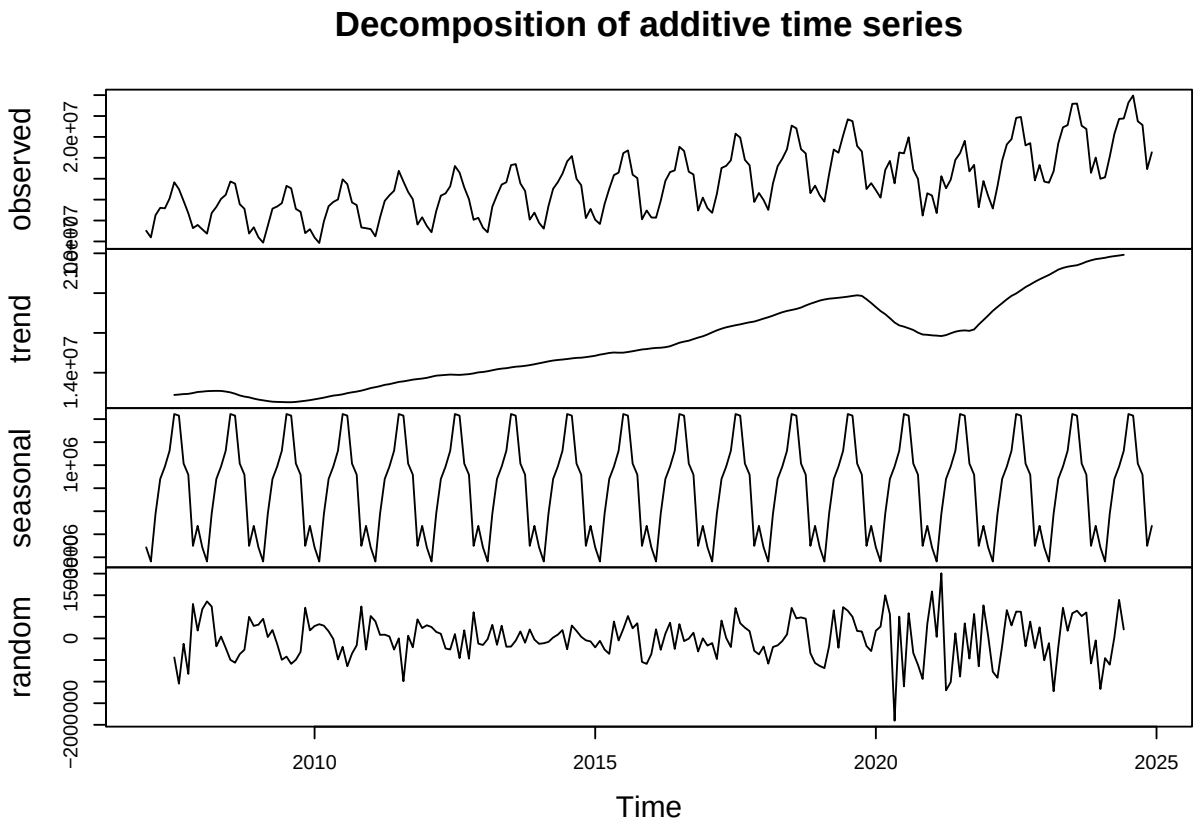


Figure 12: Décomposition classique de la série corrigée

Annexe C — Désaisonnalisation X13-SARIMA-SEATS

Annexe C.1 — Sortie complète du modèle RegARIMA-X13

```
y = regression model + arima (1, 1, 1, 0, 1, 1)

Model: RegARIMA - X13
Estimation span: from 1-2007 to 12-2024
Log-transformation: yes
Regression model: no mean, no trading days effect, no leap year effect, Easter effect, outlie

Coefficients:
ARIMA:
          Estimate Std. Error T-stat Pr(>|t|)
```

```
Phi(1)     0.39003    0.09365  4.165 4.61e-05 ***
Theta(1)  -0.43775    0.09114 -4.803 3.03e-06 ***
BTheta(1) -0.29985    0.06907 -4.341 2.24e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Regression model:
             Estimate Std. Error T-stat Pr(>|t|)
Easter [15]   0.021393   0.006877  3.111  0.00214 **
LS (5-2020)  -0.138035   0.015881 -8.692 1.33e-15 ***
LS (4-2021)  -0.152899   0.017080 -8.952 2.22e-16 ***
TC (10-2020) -0.108522   0.017152 -6.327 1.57e-09 ***
TC (4-2020)  -0.084340   0.017686 -4.769 3.54e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 0.02535 on 194 degrees of freedom
Log likelihood =   457, aic =  5823, aicc =  5824, bic(corrected for length) = -
7.14
```

Annexe C.2 — Test de transformation log / niveau

```
 tfunction adjust aicdiff
      Auto   None      -2
```

Annexe C.3 — Diagnostics des résidus du modèle X13

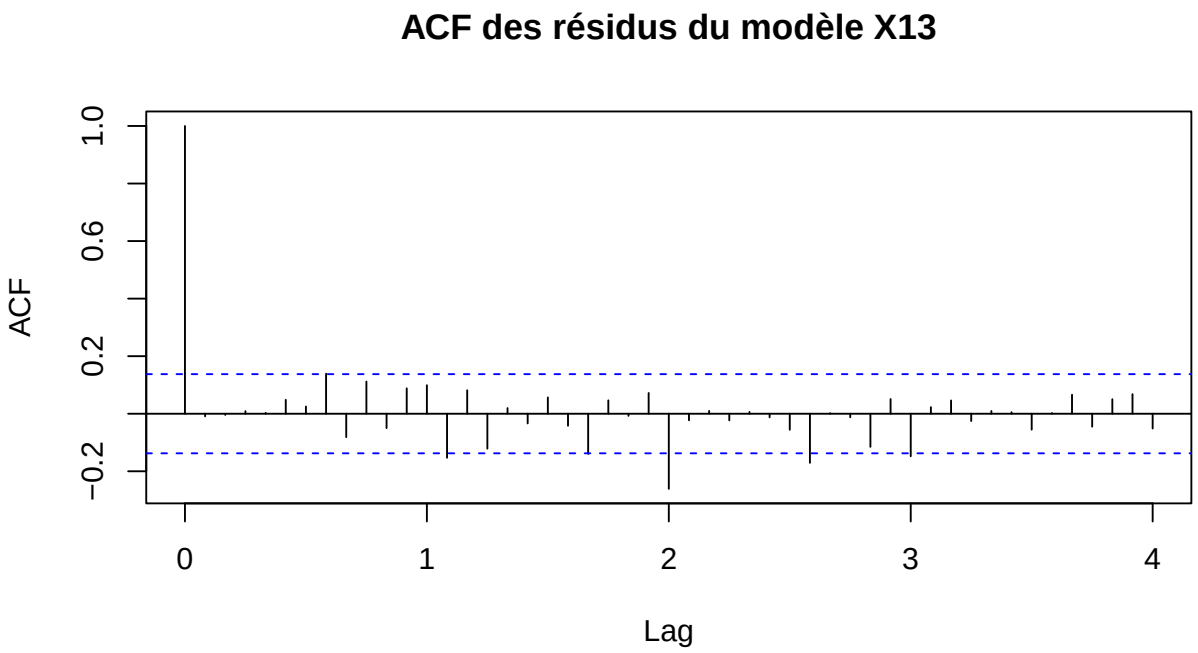


Figure 13: ACF des résidus du modèle X13

```
    Box-Ljung test

data:  res_x13
X-squared = 13.26, df = 12, p-value = 0.3504
```

Annexe D — Méthodes de référence

Annexe D.1 — Prévisions naïves saisonnières

Table 14: Prévisions complètes de la méthode naïve saisonnière

Date	Prévision
janvier 2025	15 996 676
février 2025	16 137 550
mars 2025	18 110 638
avril 2025	20 297 230
mai 2025	21 724 116

juin 2025	21 759 697
juillet 2025	23 286 812
août 2025	23 958 993
septembre 2025	21 495 882
octobre 2025	21 143 818
novembre 2025	16 917 545
décembre 2025	18 532 661

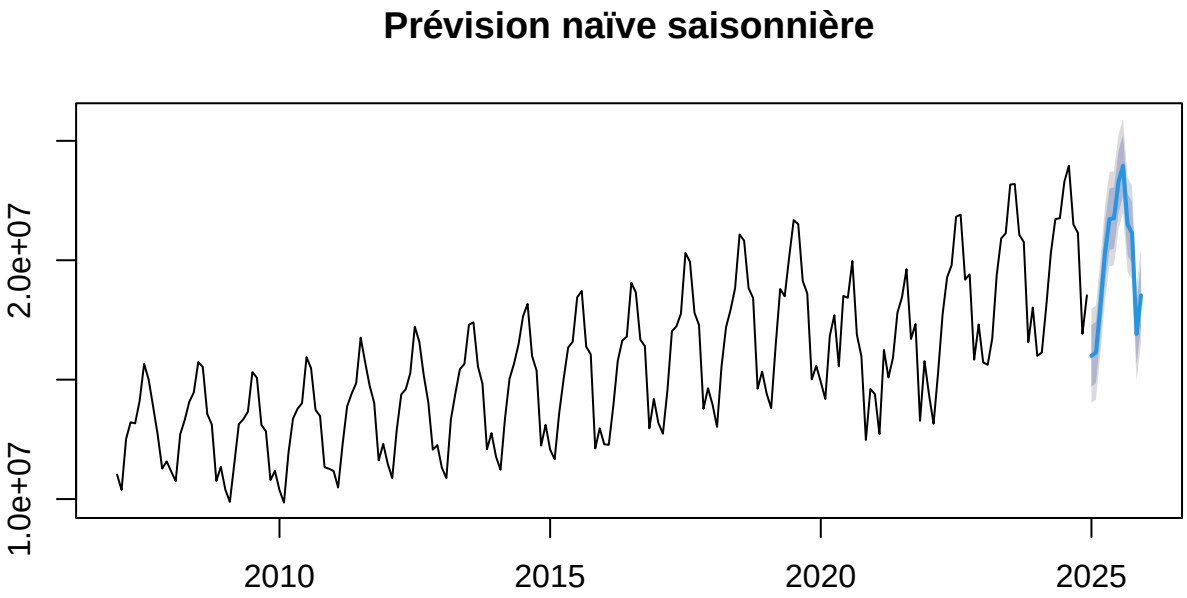


Figure 14: Prévision naïve saisonnière

Annexe D.2 — Prévisions X13-SARIMA-SEATS

Table 15: Prévisions complètes X13-SARIMA-SEATS

Date	Prévision
janvier 2025	16 610 588
février 2025	16 539 949
mars 2025	18 151 941
avril 2025	21 247 739
mai 2025	22 388 022
juin 2025	22 568 124
juillet 2025	24 295 134

août 2025	24 833 026
septembre 2025	22 273 269
octobre 2025	21 985 307
novembre 2025	17 582 005
décembre 2025	19 262 086

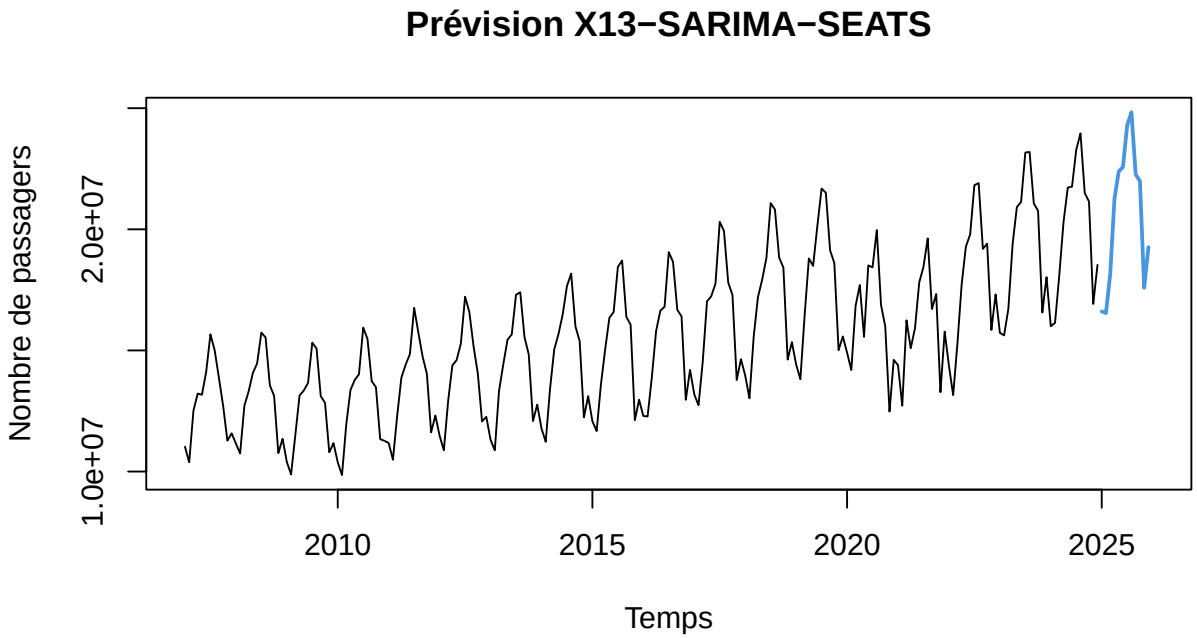


Figure 15: Prévision X13-SARIMA-SEATS

Annexe D.3 — Prévisions STL

Table 16: Prévisions complètes STL

Date	Prévision
janvier 2025	17 523 199
février 2025	16 909 278
mars 2025	18 987 526
avril 2025	20 457 167
mai 2025	20 963 801
juin 2025	21 667 825
juillet 2025	23 293 291
août 2025	23 265 396

septembre 2025	21 164 520
octobre 2025	20 682 121
novembre 2025	17 529 208
décembre 2025	18 432 754

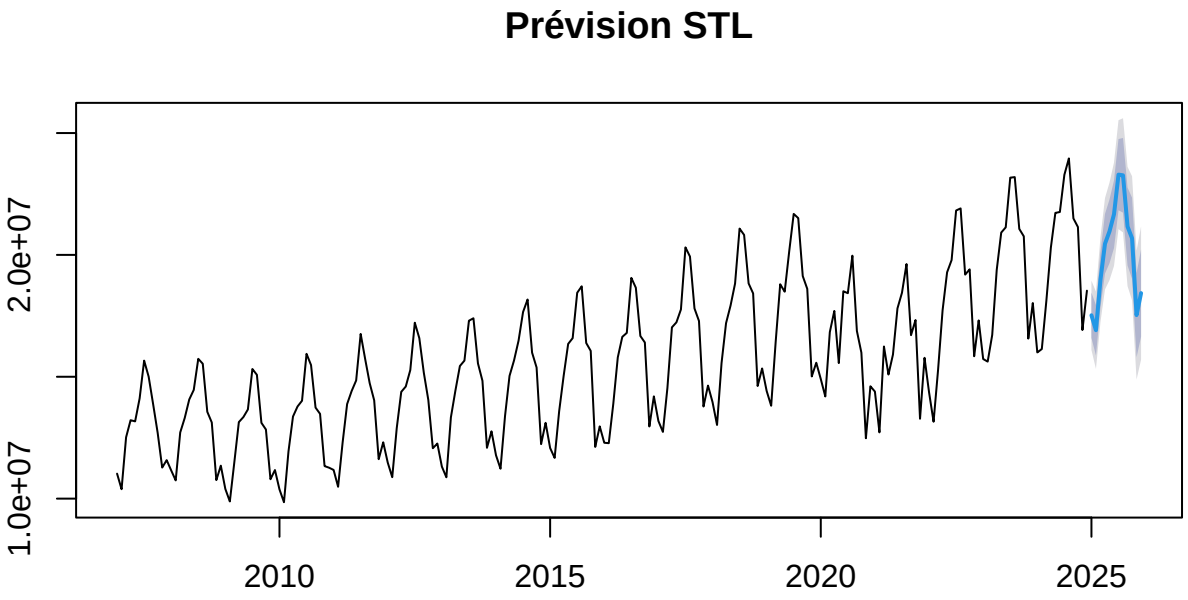


Figure 16: Prévision STL

Annexe D.4 — Prévisions STS

Table 17: Variances estimées du modèle STS

Composante	Variance
level	127790809765
slope	317819464
seas	224810754892
epsilon	0

Table 18: Prévisions complètes STS

Date	Prévision
janvier 2025	16 866 977

février 2025	16 788 255
mars 2025	18 534 589
avril 2025	20 587 071
mai 2025	21 952 486
juin 2025	21 987 211
juillet 2025	23 534 885
août 2025	24 188 639
septembre 2025	21 801 872
octobre 2025	21 586 158
novembre 2025	17 493 968
décembre 2025	19 175 491

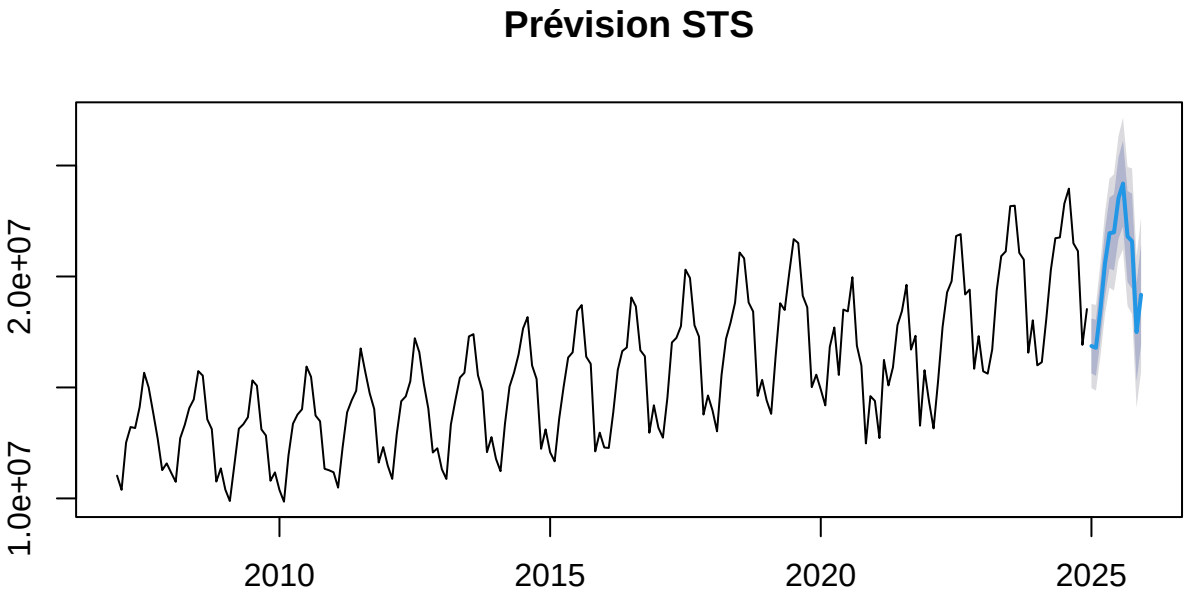


Figure 17: Prévision STS

Annexe E — Méthodes de lissage exponentiel

Annexe E.1 — Holt-Winters

```
Holt-Winters' additive method

Call:
hw(y = serie_corrigee, h = 12, seasonal = "additive")
```

```
  Smoothing parameters:
    alpha = 0.4922
    beta  = 0.0033
    gamma = 1e-04

  Initial states:
    l = 13056737.7152
    b = -1295.9525
    s = -1635797 -2503696 586492.5 1069719 3151115 3220491
           1626615 941780.6 402737.6 -1104482 -3181161 -2573814

  sigma:  583335.9

     AIC     AICc      BIC
6913.893 6916.983 6971.272
```

Table 19: Critères d'information du modèle Holt-Winters

Critère	Valeur
AIC	6913,893
AICc	6916,983

Table 20: Prévisions complètes Holt-Winters

Date	Prévision
janvier 2025	17 555 613
février 2025	16 978 524
mars 2025	19 085 493
avril 2025	20 622 924
mai 2025	21 192 228
juin 2025	21 907 418
juillet 2025	23 531 641
août 2025	23 492 606
septembre 2025	21 441 416
octobre 2025	20 988 497
novembre 2025	17 928 494
décembre 2025	18 826 824

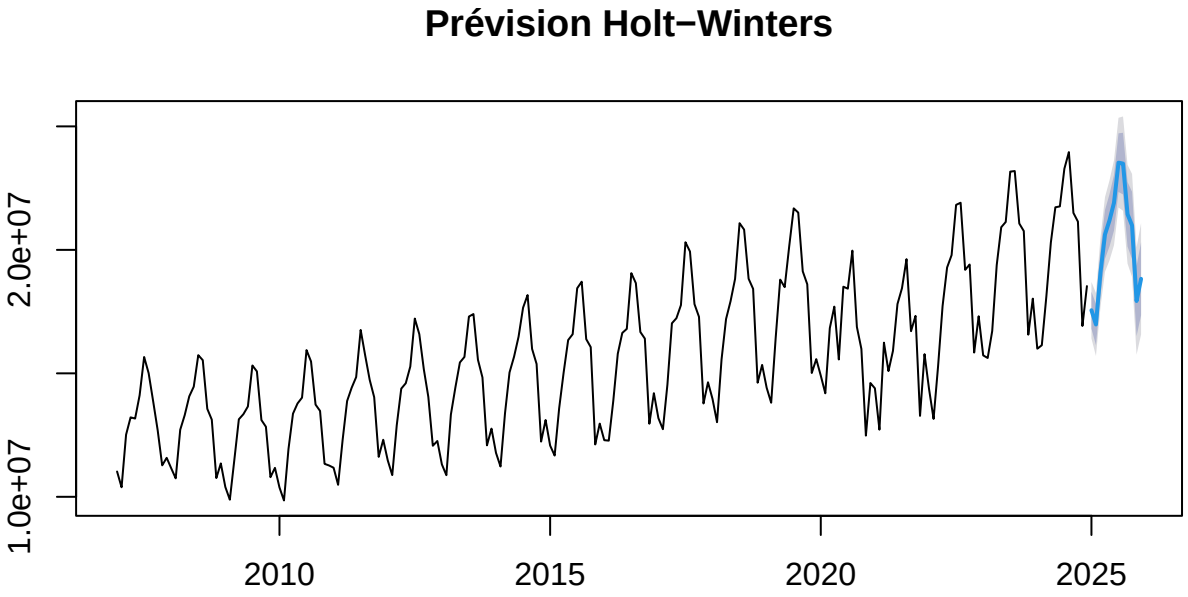


Figure 18: Prévision Holt-Winters

Annexe E.2 — ETS

```
ETS(M,Ad,M)

Call:
ets(y = serie_corrigee)

  Smoothing parameters:
    alpha = 0.4065
    beta  = 0.0085
    gamma = 1e-04
    phi   = 0.9761

  Initial states:
    l = 13031895.8659
    b = -3799.9162
    s = 0.893 0.837 1.0348 1.0677 1.2045 1.2099
           1.1039 1.0621 1.0274 0.9321 0.7932 0.8344

  sigma:  0.0326

     AIC     AICc      BIC
6843.232 6846.704 6903.987
```

```
Training set error measures:
                    ME     RMSE      MAE       MPE     MAPE     MASE        ACF1
Training set 55857.76 509582.3 349364.8 0.2651501 2.236853 0.465213 -0.06734134
```

Table 21: Critères d'information du modèle ETS

Critère	Valeur
AIC	6843,232
AICc	6846,704

Table 22: Prévisions complètes ETS

Date	Prévision
janvier 2025	17 086 751
février 2025	16 270 089
mars 2025	19 150 805
avril 2025	21 143 595
mai 2025	21 893 173
juin 2025	22 788 640
juillet 2025	25 015 179
août 2025	24 939 026
septembre 2025	22 138 287
octobre 2025	21 485 063
novembre 2025	17 401 942
décembre 2025	18 590 266

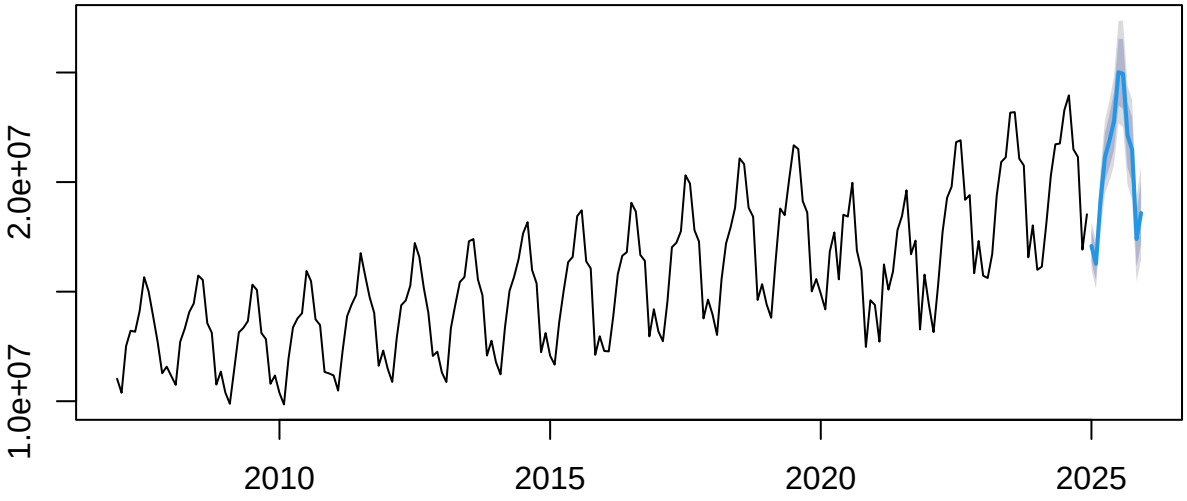


Figure 19: Prévision ETS

Annexe E.3 — TBATS

```
TBATS(0, {2,0}, 1, {<12,5>})

Call: tbats(y = serie_corrigee)

Parameters
  Lambda: 2e-04
  Alpha: 0.3090939
  Beta: 0.002743234
  Damping Parameter: 1
  Gamma-1 Values: -0.006488433
  Gamma-2 Values: 0.003720352
  AR coefficients: -0.014142 0.29644

Seed States:
               [,1]
 [1,] 16.3669247118
 [2,]  0.0047636808
 [3,] -0.1835272326
 [4,] -0.0032109787
 [5,]  0.0001376893
 [6,]  0.0271748028
```

```
 [7,] -0.0021422949
 [8,] -0.0040698407
 [9,]  0.0126952759
[10,] -0.0325868224
[11,] -0.0212078026
[12,] -0.0326113718
[13,]  0.0000000000
[14,]  0.0000000000
attr(,"lambda")
[1] 0.0002000461

Sigma: 0.03244415
AIC: 6864.542
```

Table 23: Critère d'information du modèle TBATS

Critère	Valeur
AIC	6864,542

Table 24: Prévisions complètes TBATS

Date	Prévision
janvier 2025	17 176 209
février 2025	16 378 953
mars 2025	19 409 035
avril 2025	21 097 917
mai 2025	22 207 800
juin 2025	22 843 222
juillet 2025	25 654 114
août 2025	25 024 770
septembre 2025	22 731 515
octobre 2025	21 703 819
novembre 2025	17 945 392
décembre 2025	18 774 792

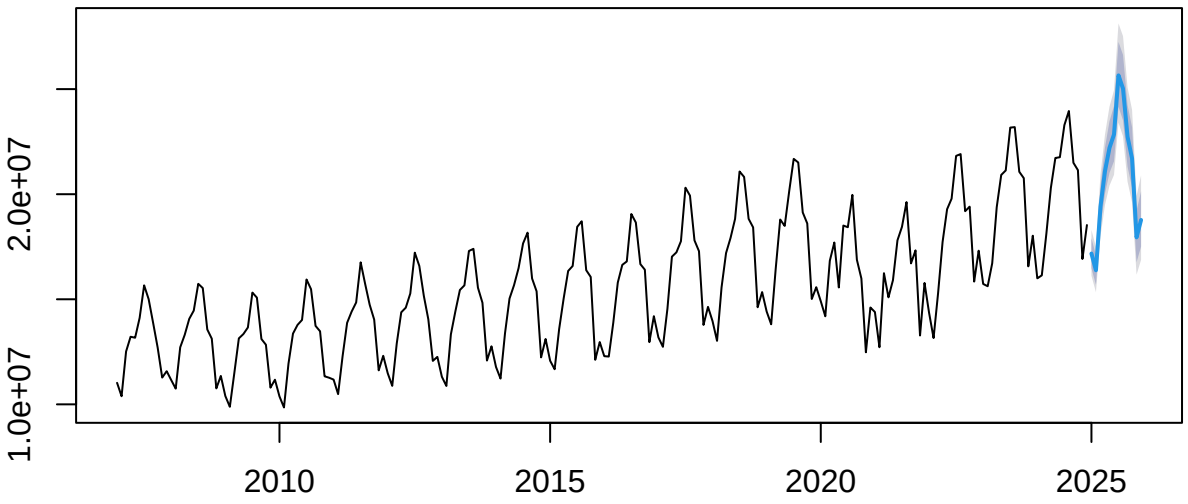


Figure 20: Prévision TBATS

Annexe E.4 — ADAM

```
Model estimated using adam() function: ETS(MAM)
Response variable: serie_corrigee
Distribution used in the estimation: Gamma
Loss function type: likelihood; Loss function value: 3134.321
Coefficients:
      Estimate Std. Error Lower 2.5% Upper 97.5%
alpha   0.4178     0.0547     0.3099      0.5257 *
beta    0.0000     0.0035     0.0000      0.0068
gamma   0.0933     0.0532     0.0000      0.1981

Error standard deviation: 0.0317
Sample size: 216
Number of estimated parameters: 4
Number of degrees of freedom: 212
Information criteria:
     AIC     AICc      BIC     BICc
6276.641 6276.831 6290.143 6290.652
```

Table 25: Critères d'information du modèle ADAM

Critère	Valeur
AIC	6276,642
AICc	6276,831

Table 26: Prévisions complètes ADAM

Date	Prévision
janvier 2025	17 016 673
février 2025	16 246 459
mars 2025	18 991 612
avril 2025	21 060 938
mai 2025	21 855 178
juin 2025	22 814 903
juillet 2025	24 888 236
août 2025	25 078 731
septembre 2025	22 180 834
octobre 2025	21 622 373
novembre 2025	17 315 822
décembre 2025	18 729 711

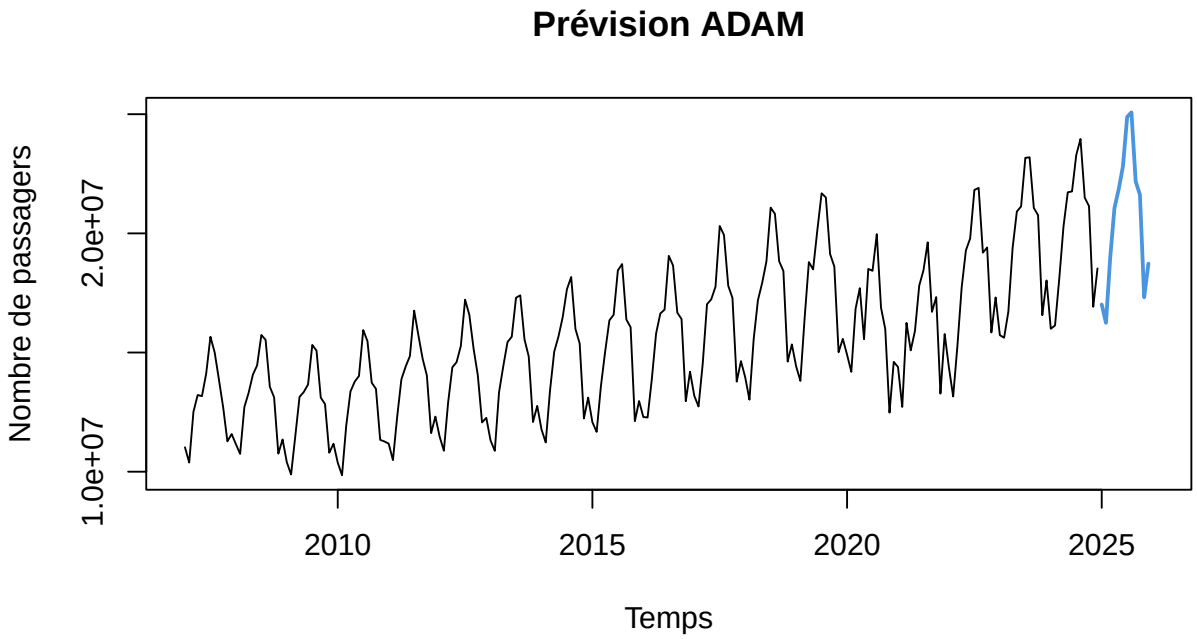


Figure 21: Prévision ADAM

Annexe F — Modèles SARIMA

Annexe F.1 — SARIMA automatique

```
Series: serie_corrigee
ARIMA(2,0,0)(0,1,2)[12] with drift

Coefficients:
         ar1     ar2     sma1     sma2      drift
      0.4079  0.4248  -0.2369  -0.4929  33708.458
s.e.  0.0633  0.0636   0.0761   0.0772   6106.962

sigma^2 = 2.458e+11:  log likelihood = -2967.43
AIC=5946.86   AICc=5947.28   BIC=5966.77

Training set error measures:
                    ME     RMSE      MAE        MPE    MAPE      MASE
Training set -9063.912 475860.6 326738.7 -0.2320064 2.12663 0.4350842
                    ACF1
Training set -0.01378716
```

Table 27: Prévisions complètes SARIMA automatique

Date	Prévision
janvier 2025	16 669 824
février 2025	16 378 256
mars 2025	18 584 960
avril 2025	20 646 143
mai 2025	21 478 295
juin 2025	21 892 809
juillet 2025	23 339 927
août 2025	23 901 492
septembre 2025	21 309 639
octobre 2025	20 914 051
novembre 2025	17 164 028
décembre 2025	18 587 612

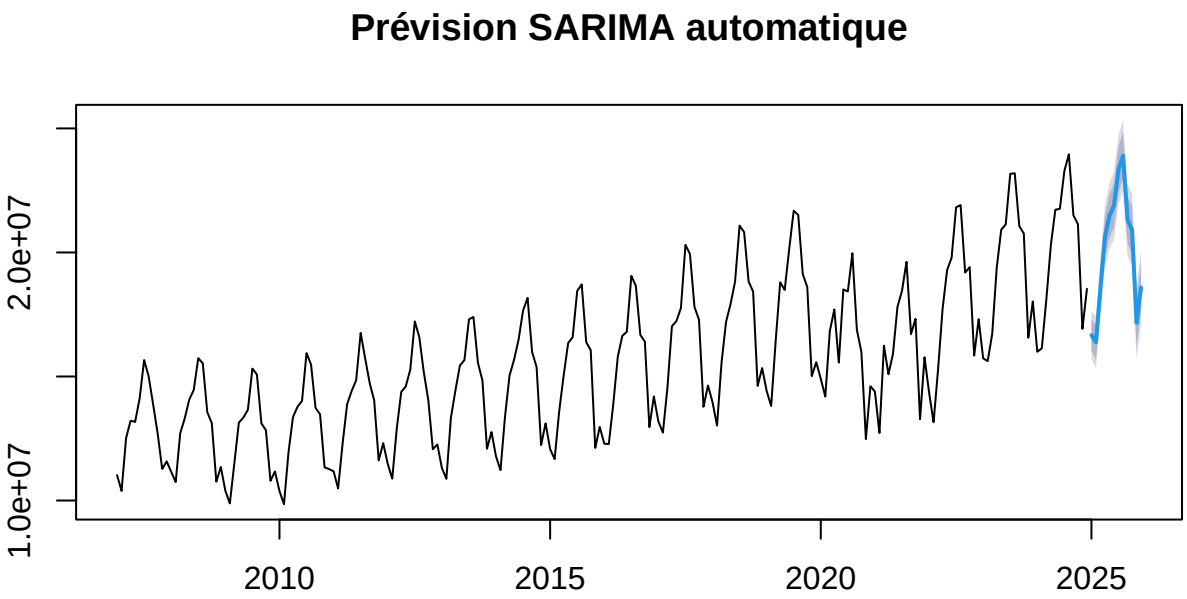


Figure 22: Prévision SARIMA automatique

Annexe F.2 — SARIMA manuel

```
Series: serie_corrigee
ARIMA(1,1,1)(0,1,1)[12]
```

```
Coefficients:
          ar1      ma1     sma1
      -0.3153  -0.2519  -0.4453
s.e.   0.1457   0.1560   0.1460

sigma^2 = 3.148e+11:  log likelihood = -2975.25
AIC=5958.5   AICc=5958.7   BIC=5971.75

Training set error measures:
                    ME     RMSE      MAE          MPE     MAPE      MASE
Training set 8802.033 539884.5 354271.1 -0.03935161 2.263782 0.4717463
                     ACF1
Training set 0.001016206
```

Table 28: Prévisions complètes SARIMA manuel

Date	Prévision
janvier 2025	16 845 411
février 2025	16 647 222
mars 2025	18 522 043
avril 2025	20 661 248
mai 2025	21 998 812
juin 2025	22 305 089
juillet 2025	23 941 984
août 2025	24 417 513
septembre 2025	21 978 073
octobre 2025	21 734 031
novembre 2025	17 622 293
décembre 2025	19 221 333

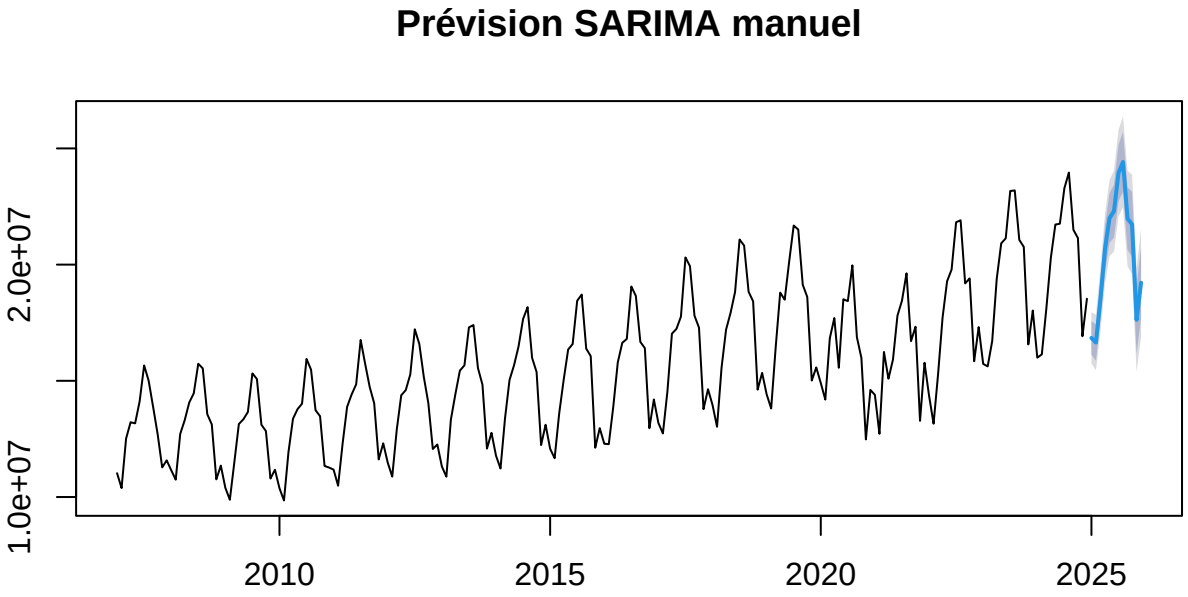


Figure 23: Prévision SARIMA manuel

Annexe F.3 — SSARIMA

```
Series: serie_sa
ARIMA(0,1,1) with drift

Coefficients:
          ma1     drift
      -0.5057  33012.99
s.e.   0.0561  14579.19

sigma^2 = 1.87e+11:  log likelihood = -3094.32
AIC=6194.64   AICc=6194.76   BIC=6204.75

Training set error measures:
                    ME     RMSE      MAE         MPE     MAPE      MASE
Training set -788.2313 429444.8 268125.4 -0.09315988 1.732714 0.3617009
                    ACF1
Training set -0.02786649
```

Table 29: Prévisions complètes SSARIMA

Date	Prévision

janvier 2025	16 725 476
février 2025	16 292 105
mars 2025	18 469 407
avril 2025	20 473 676
mai 2025	22 114 632
juin 2025	22 424 875
juillet 2025	24 193 765
août 2025	24 553 485
septembre 2025	21 855 269
octobre 2025	21 644 944
novembre 2025	17 262 418
décembre 2025	18 858 310

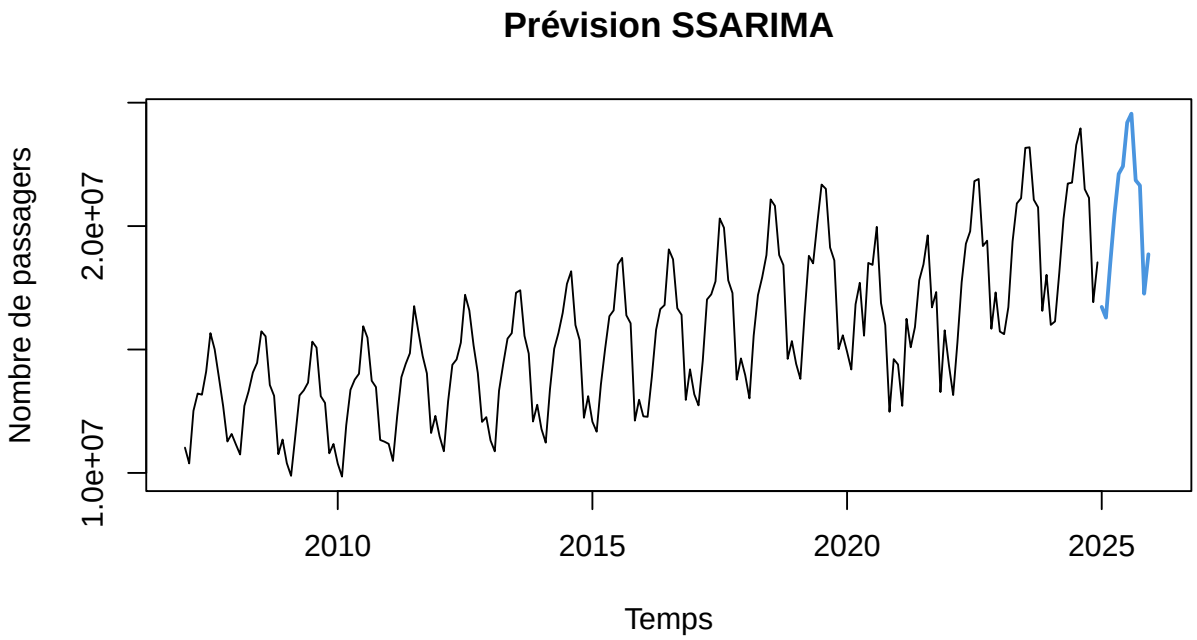


Figure 24: Prévision SSARIMA

Annexe G — Comparaison des modèles

Annexe G.1 — Tableau complet des prévisions par modèle

Table 30: Prévisions mensuelles complètes pour 2025 selon les modèles

Date	Modèle	Prévision
janvier 2025	Naïve saisonnière	15 996 676
janvier 2025	X13	16 610 588
janvier 2025	STL	17 523 199
janvier 2025	STS	16 866 977
janvier 2025	Holt-Winters	17 555 613
janvier 2025	ETS	17 086 751
janvier 2025	TBATS	17 176 209
janvier 2025	ADAM	17 016 673
janvier 2025	SARIMA automatique	16 669 824
janvier 2025	SARIMA manuel	16 845 411
janvier 2025	SSARIMA	16 725 476
février 2025	Naïve saisonnière	16 137 550
février 2025	X13	16 539 949
février 2025	STL	16 909 278
février 2025	STS	16 788 255
février 2025	Holt-Winters	16 978 524
février 2025	ETS	16 270 089
février 2025	TBATS	16 378 953
février 2025	ADAM	16 246 459
février 2025	SARIMA automatique	16 378 256
février 2025	SARIMA manuel	16 647 222
février 2025	SSARIMA	16 292 105
mars 2025	Naïve saisonnière	18 110 638
mars 2025	X13	18 151 941
mars 2025	STL	18 987 526
mars 2025	STS	18 534 589
mars 2025	Holt-Winters	19 085 493
mars 2025	ETS	19 150 805
mars 2025	TBATS	19 409 035
mars 2025	ADAM	18 991 612
mars 2025	SARIMA automatique	18 584 960
mars 2025	SARIMA manuel	18 522 043
mars 2025	SSARIMA	18 469 407
avril 2025	Naïve saisonnière	20 297 230
avril 2025	X13	21 247 739
avril 2025	STL	20 457 167
avril 2025	STS	20 587 071
avril 2025	Holt-Winters	20 622 924

avril 2025	ETS	21 143 595
avril 2025	TBATS	21 097 917
avril 2025	ADAM	21 060 938
avril 2025	SARIMA automatique	20 646 143
avril 2025	SARIMA manuel	20 661 248
avril 2025	SSARIMA	20 473 676
mai 2025	Naïve saisonnière	21 724 116
mai 2025	X13	22 388 022
mai 2025	STL	20 963 801
mai 2025	STS	21 952 486
mai 2025	Holt-Winters	21 192 228
mai 2025	ETS	21 893 173
mai 2025	TBATS	22 207 800
mai 2025	ADAM	21 855 178
mai 2025	SARIMA automatique	21 478 295
mai 2025	SARIMA manuel	21 998 812
mai 2025	SSARIMA	22 114 632
juin 2025	Naïve saisonnière	21 759 697
juin 2025	X13	22 568 124
juin 2025	STL	21 667 825
juin 2025	STS	21 987 211
juin 2025	Holt-Winters	21 907 418
juin 2025	ETS	22 788 640
juin 2025	TBATS	22 843 222
juin 2025	ADAM	22 814 903
juin 2025	SARIMA automatique	21 892 809
juin 2025	SARIMA manuel	22 305 089
juin 2025	SSARIMA	22 424 875
juillet 2025	Naïve saisonnière	23 286 812
juillet 2025	X13	24 295 134
juillet 2025	STL	23 293 291
juillet 2025	STS	23 534 885
juillet 2025	Holt-Winters	23 531 641
juillet 2025	ETS	25 015 179
juillet 2025	TBATS	25 654 114
juillet 2025	ADAM	24 888 236
juillet 2025	SARIMA automatique	23 339 927
juillet 2025	SARIMA manuel	23 941 984
juillet 2025	SSARIMA	24 193 765

août 2025	Naïve saisonnière	23 958 993
août 2025	X13	24 833 026
août 2025	STL	23 265 396
août 2025	STS	24 188 639
août 2025	Holt-Winters	23 492 606
août 2025	ETS	24 939 026
août 2025	TBATS	25 024 770
août 2025	ADAM	25 078 731
août 2025	SARIMA automatique	23 901 492
août 2025	SARIMA manuel	24 417 513
août 2025	SSARIMA	24 553 485
septembre 2025	Naïve saisonnière	21 495 882
septembre 2025	X13	22 273 269
septembre 2025	STL	21 164 520
septembre 2025	STS	21 801 872
septembre 2025	Holt-Winters	21 441 416
septembre 2025	ETS	22 138 287
septembre 2025	TBATS	22 731 515
septembre 2025	ADAM	22 180 834
septembre 2025	SARIMA automatique	21 309 639
septembre 2025	SARIMA manuel	21 978 073
septembre 2025	SSARIMA	21 855 269
octobre 2025	Naïve saisonnière	21 143 818
octobre 2025	X13	21 985 307
octobre 2025	STL	20 682 121
octobre 2025	STS	21 586 158
octobre 2025	Holt-Winters	20 988 497
octobre 2025	ETS	21 485 063
octobre 2025	TBATS	21 703 819
octobre 2025	ADAM	21 622 373
octobre 2025	SARIMA automatique	20 914 051
octobre 2025	SARIMA manuel	21 734 031
octobre 2025	SSARIMA	21 644 944
novembre 2025	Naïve saisonnière	16 917 545
novembre 2025	X13	17 582 005
novembre 2025	STL	17 529 208
novembre 2025	STS	17 493 968
novembre 2025	Holt-Winters	17 928 494
novembre 2025	ETS	17 401 942

novembre 2025	TBATS	17 945 392
novembre 2025	ADAM	17 315 822
novembre 2025	SARIMA automatique	17 164 028
novembre 2025	SARIMA manuel	17 622 293
novembre 2025	SSARIMA	17 262 418
décembre 2025	Naïve saisonnière	18 532 661
décembre 2025	X13	19 262 086
décembre 2025	STL	18 432 754
décembre 2025	STS	19 175 491
décembre 2025	Holt-Winters	18 826 824
décembre 2025	ETS	18 590 266
décembre 2025	TBATS	18 774 792
décembre 2025	ADAM	18 729 711
décembre 2025	SARIMA automatique	18 587 612
décembre 2025	SARIMA manuel	19 221 333
décembre 2025	SSARIMA	18 858 310

Annexe H — Évaluation out-of-sample

Annexe H.1 — Données détaillées du CSPE

Table 31: Données détaillées du CSPE par modèle

Date	Modèle	CSPE
janvier 2024	Naïve saisonnière	7,219111e+10
janvier 2024	X13-SARIMA-SEATS	4,082765e+10
janvier 2024	STL	1,317937e+12
janvier 2024	STS	1,130231e+12
janvier 2024	Holt-Winters	1,368316e+12
janvier 2024	ETS	5,446331e+11
janvier 2024	TBATS	3,667700e+11
janvier 2024	ADAM	4,919591e+11
janvier 2024	SARIMA automatique	6,308787e+11
janvier 2024	SARIMA manuel	1,067075e+12
janvier 2024	SSARIMA	7,953428e+10
février 2024	Naïve saisonnière	3,389984e+11
février 2024	X13-SARIMA-SEATS	5,858638e+11
février 2024	STL	1,441283e+12
février 2024	STS	1,429013e+12

février 2024	Holt-Winters	1,550798e+12
février 2024	ETS	6,003962e+11
février 2024	TBATS	5,407124e+11
février 2024	ADAM	5,935820e+11
février 2024	SARIMA automatique	6,968148e+11
février 2024	SARIMA manuel	1,083225e+12
février 2024	SSARIMA	1,825708e+12
mars 2024	Naïve saisonnière	2,287144e+12
mars 2024	X13-SARIMA-SEATS	5,860804e+11
mars 2024	STL	1,657451e+12
mars 2024	STS	1,585532e+12
mars 2024	Holt-Winters	1,881392e+12
mars 2024	ETS	1,010784e+12
mars 2024	TBATS	8,671155e+11
mars 2024	ADAM	8,331089e+11
mars 2024	SARIMA automatique	7,018708e+11
mars 2024	SARIMA manuel	1,096270e+12
mars 2024	SSARIMA	2,248132e+12
avril 2024	Naïve saisonnière	3,125303e+12
avril 2024	X13-SARIMA-SEATS	9,412983e+11
avril 2024	STL	1,742564e+12
avril 2024	STS	1,598229e+12
avril 2024	Holt-Winters	1,895784e+12
avril 2024	ETS	1,180320e+12
avril 2024	TBATS	8,767842e+11
avril 2024	ADAM	9,160399e+11
avril 2024	SARIMA automatique	1,411064e+12
avril 2024	SARIMA manuel	1,136776e+12
avril 2024	SSARIMA	2,324932e+12
mai 2024	Naïve saisonnière	3,777473e+12
mai 2024	X13-SARIMA-SEATS	9,604122e+11
mai 2024	STL	3,339454e+12
mai 2024	STS	1,641189e+12
mai 2024	Holt-Winters	2,954829e+12
mai 2024	ETS	1,275241e+12
mai 2024	TBATS	1,105436e+12
mai 2024	ADAM	1,104238e+12
mai 2024	SARIMA automatique	2,444397e+12
mai 2024	SARIMA manuel	1,503797e+12
mai 2024	SSARIMA	2,543913e+12

juin 2024	Naïve saisonnière	4,173726e+12
juin 2024	X13-SARIMA-SEATS	1,116359e+12
juin 2024	STL	3,647596e+12
juin 2024	STS	1,663679e+12
juin 2024	Holt-Winters	3,047643e+12
juin 2024	ETS	1,631901e+12
juin 2024	TBATS	1,113221e+12
juin 2024	ADAM	1,463354e+12
juin 2024	SARIMA automatique	2,654946e+12
juin 2024	SARIMA manuel	1,535502e+12
juin 2024	SSARIMA	2,633376e+12
juillet 2024	Naïve saisonnière	4,187540e+12
juillet 2024	X13-SARIMA-SEATS	1,462944e+12
juillet 2024	STL	3,850237e+12
juillet 2024	STS	1,745717e+12
juillet 2024	Holt-Winters	3,100012e+12
juillet 2024	ETS	3,378343e+12
juillet 2024	TBATS	2,817385e+12
juillet 2024	ADAM	2,699867e+12
juillet 2024	SARIMA automatique	2,739458e+12
juillet 2024	SARIMA manuel	1,635915e+12
juillet 2024	SSARIMA	3,084877e+12
août 2024	Naïve saisonnière	4,775883e+12
août 2024	X13-SARIMA-SEATS	1,846771e+12
août 2024	STL	5,267586e+12
août 2024	STS	1,905564e+12
août 2024	Holt-Winters	3,987050e+12
août 2024	ETS	3,650488e+12
août 2024	TBATS	2,827091e+12
août 2024	ADAM	2,993591e+12
août 2024	SARIMA automatique	3,502571e+12
août 2024	SARIMA manuel	1,639647e+12
août 2024	SSARIMA	3,154554e+12
septembre 2024	Naïve saisonnière	4,960162e+12
septembre 2024	X13-SARIMA-SEATS	1,967043e+12
septembre 2024	STL	5,917373e+12
septembre 2024	STS	1,908239e+12
septembre 2024	Holt-Winters	4,257557e+12
septembre 2024	ETS	3,715338e+12
septembre 2024	TBATS	2,912211e+12

septembre 2024	ADAM	3,011010e+12
septembre 2024	SARIMA automatique	3,800727e+12
septembre 2024	SARIMA manuel	1,643312e+12
septembre 2024	SSARIMA	3,159555e+12
octobre 2024	Naïve saisonnière	5,105088e+12
octobre 2024	X13-SARIMA-SEATS	2,009445e+12
octobre 2024	STL	6,806022e+12
octobre 2024	STS	1,934466e+12
octobre 2024	Holt-Winters	4,647119e+12
octobre 2024	ETS	3,719818e+12
octobre 2024	TBATS	3,063875e+12
octobre 2024	ADAM	3,015081e+12
octobre 2024	SARIMA automatique	3,905403e+12
octobre 2024	SARIMA manuel	1,675748e+12
octobre 2024	SSARIMA	3,264292e+12
novembre 2024	Naïve saisonnière	5,228928e+12
novembre 2024	X13-SARIMA-SEATS	2,254936e+12
novembre 2024	STL	6,844136e+12
novembre 2024	STS	2,102684e+12
novembre 2024	Holt-Winters	5,028836e+12
novembre 2024	ETS	3,748706e+12
novembre 2024	TBATS	3,105223e+12
novembre 2024	ADAM	3,016166e+12
novembre 2024	SARIMA automatique	3,981745e+12
novembre 2024	SARIMA manuel	1,926521e+12
novembre 2024	SSARIMA	3,278466e+12
décembre 2024	Naïve saisonnière	5,486550e+12
décembre 2024	X13-SARIMA-SEATS	2,255274e+12
décembre 2024	STL	7,155202e+12
décembre 2024	STS	2,243269e+12
décembre 2024	Holt-Winters	5,045779e+12
décembre 2024	ETS	3,848868e+12
décembre 2024	TBATS	3,522795e+12
décembre 2024	ADAM	3,092995e+12
décembre 2024	SARIMA automatique	4,209327e+12
décembre 2024	SARIMA manuel	2,146695e+12
décembre 2024	SSARIMA	3,318622e+12